

前置知识三：VC维度

1. VC维度的定义

VC维度 (Vapnik–Chervonenkis Dimension) 是用来**衡量一个假设空间 (Hypothesis Space) 的学习能力或复杂度**。它由 Vladimir Vapnik 和 Alexey Chervonenkis 在 20 世纪 70 年代提出。

在机器学习中，我们通常希望从训练数据中学习一个分类函数：

$$h : X \rightarrow \{-1, +1\}$$

其中：

- X 表示输入空间；
- h 表示分类器；
- $\mathcal{H}$ 表示所有可能的分类器集合，即假设空间。

VC维度描述的是：

一个假设空间能够完全拟合多少个任意位置的数据点。

更严格地说，若存在 m 个样本点：

$$S = \{x_1, x_2, \dots, x_m\}$$

对于这 m 个点的任意二分类标记：

$$(y_1, y_2, \dots, y_m), \quad y_i \in \{-1, +1\}$$

都存在某个假设 $h \in \mathcal{H}$ ，满足：

$$h(x_i) = y_i, \quad i = 1, 2, \dots, m$$

则称假设空间 $\mathcal{H}$ 打散 (Shatter) 了这 m 个点。

VC维度定义为：

$$VC(\mathcal{H}) = \max\{m : \mathcal{H} \text{ 能够打散 } m \text{ 个点}\}$$

如果一个假设空间能够打散任意大的数据集，则：

$$VC(\mathcal{H}) = \infty$$

2. VC维度的直观理解

VC维度本质上衡量模型的表达能力。可以简单理解为：

- VC维度越大，模型越复杂；
- VC维度越小，模型越简单。


栗子：一维阈值分类器

假设：

$$h(x) = \begin{cases} 1, & x \geq a \\ -1, & x < a \end{cases}$$

其中 a 是分类边界。

对于任意一个点：



可以通过调整 a 使其属于任意类别，因此：

$$VC(\mathcal{H}) \geq 1$$

但是对于两个点 $x_1 < x_2$ ，如果要求标签为 $(+1, -1)$ ，则无法实现，因为阈值只能产生：

$$(-1, -1), (-1, +1), (+1, +1)$$

三种情况。所以：

$$VC(\mathcal{H}) = 1$$

3. VC维度为什么重要？

防止过拟合

机器学习的目标不是简单记忆训练数据，而是获得泛化能力。

训练误差（经验风险）：

$$R_{emp}(h) = \frac{1}{n} \sum_{i=1}^n L(h(x_i), y_i)$$

但我们真正关心的是期望风险：

$$R(h) = \mathbb{E}_{(x,y)} [L(h(x), y)]$$

统计学习理论证明：对于任意假设 $h \in \mathcal{H}$ ，有：

$$R(h) \leq R_{emp}(h) + \sqrt{\frac{VC(\mathcal{H}) \left(\ln \frac{2n}{VC(\mathcal{H})} + 1 \right) + \ln \frac{4}{\delta}}{n}}$$

其中：

- n ：训练样本数量；
- δ ：置信水平；
- $VC(\mathcal{H})$ ：模型复杂度。

这个公式说明，模型泛化误差由两部分组成：

$$\text{泛化误差} = \text{训练误差} + \text{复杂度惩罚}$$

其中 $\sqrt{\frac{VC(\mathcal{H})}{n}}$ 表示模型复杂度带来的风险。

因此：

- **VC维太大** $\Rightarrow$ 模型容易记住噪声，产生**过拟合**；
- **VC维太小** $\Rightarrow$ 模型表达能力不足，产生**欠拟合**。

4. 常见模型的VC维度

4.1 线性分类器

考虑：

$$h(x) = \text{sign}(w^T x + b)$$

其中 $w \in \mathbb{R}^d$ ，表示一个 d 维超平面。

对于 d 维空间：

$$VC(\mathcal{H}) = d + 1$$

例如二维平面 $x = (x_1, x_2)$ ，线性分类器：

$$w_1 x_1 + w_2 x_2 + b = 0$$

其 VC 维为：

$$VC = 3$$

意味着：二维直线分类器最多可以任意分类 3 个点。

4.2 神经网络

对于具有 W 个参数、使用 ReLU 激活函数的神经网络，VC 维通常满足：

$$VC(\mathcal{H}) = O(W \log W)$$

其中 W 表示网络参数数量。

例如，一个神经网络若 $W = 10^6$ ，则：

$$VC(\mathcal{H}) \approx O(10^6 \log 10^6)$$

说明深度神经网络具有极强的表达能力。

5. VC维度计算示例

示例：二维线性分类器

假设：

$$h(x) = \text{sign}(w_1x_1 + w_2x_2 + b)$$

问题：求 VC 维。


第一步：证明可以打散 3 个点

取三个不共线点 x_1, x_2, x_3 ，对于任意标签 (y_1, y_2, y_3) ，都可以找到一条直线进行分类。因此：

$$VC \geq 3$$

第二步：证明不能打散 4 个点

任取 4 个点，根据二维空间性质，其中至少存在一个点位于其他三个点形成的凸包内部。如果该点标签与外围三个点相反：



任何直线都无法完成分类，因此：

$$VC < 4$$

最终：

$$VC = 3$$

6. VC维度在机器学习中的应用

6.1 模型选择

VC 维可以指导模型复杂度选择。例如：

- 模型 A: $VC = 100$
- 模型 B: $VC = 100000$

如果训练数据 $n = 1000$, 模型 B 可能 $VC \gg n$, 导致 $\sqrt{\frac{VC}{n}}$ 很大。因此选择模型 A 可能具有更好的泛化能力。

6.2 支持向量机 (SVM)

SVM 通过最大化间隔 γ 降低有效 VC 维。对于线性分类器:

$$VC \leq \min \left(\frac{R^2}{\gamma^2}, d \right)$$

其中:

- R : 数据范围;
- γ : 分类间隔。

间隔越大 ($\gamma \uparrow$), 则 VC 维越小 ($VC \downarrow$), 所以 SVM 具有较强泛化能力。

6.3 深度学习中的应用

传统理论认为:

$$VC \text{ 越大} \Rightarrow \text{更容易过拟合}$$

但是现代深度学习发现: 大型神经网络 $VC(\mathcal{H}) \gg n$, 仍然能够很好泛化。例如 GPT 类模型 $W \approx 10^{11}$, 参数远大于训练样本数量。

这促使人们提出新的理论, 研究模型为什么能够突破传统 VC 理论的限制:

- 双下降理论 (Double Descent)
- 神经切线核理论 (NTK)
- 隐式正则化理论