

前置知识四：嵌入

1. 嵌入的定义

基本概念

嵌入 (Embedding) 是机器学习和人工智能领域中一种将离散对象（如文本、图像、用户、物品、节点等）映射到连续低维向量空间的技术，使得原始对象之间的语义关系能够通过向量之间的数学关系表示。

简单来说：

嵌入就是把"无法直接计算的对象"转换成"计算机可以理解的数字向量"。

数学上，一个嵌入过程可以表示为：

$$f : X \rightarrow \mathbb{R}^d$$

其中：

- X 表示原始数据空间，例如单词集合：

$$X = \{w_1, w_2, \dots, w_n\}$$

- d 表示嵌入维度，一般远小于原始空间大小：

$$d \ll |X|$$

- $f(w_i)$ 表示对象 w_i 的向量表示：

$$f(w_i) = \mathbf{x}_i = [x_1, x_2, \dots, x_d]^T$$

例如：

"猫" $\rightarrow [0.23, 0.56, -0.12, \dots, 0.41]$

"狗" $\rightarrow [0.21, 0.52, -0.10, \dots, 0.39]$

"汽车" $\rightarrow [-0.76, 0.11, 0.88, \dots, -0.32]$

计算机不理解"猫"和"狗"的概念，但可以通过向量之间的距离发现：

$$distance(\text{猫}, \text{狗}) < distance(\text{猫}, \text{汽车})$$

因此认为猫和狗更加相似。

2. 为什么需要嵌入

2.1 传统表示方法的问题

在嵌入出现之前，计算机通常使用 **One-hot 编码**。

例如词表：

$$V = \{\text{猫}, \text{狗}, \text{汽车}\}$$

表示：

$$\text{猫} = [1, 0, 0]$$

$$\text{狗} = [0, 1, 0]$$

$$\text{汽车} = [0, 0, 1]$$

数学形式：

$$x_i \in \{0, 1\}^{|V|}$$

但是这种方法存在三个问题：

问题 1：维度过高

如果词表大小：

$$|V| = 100000$$

那么每个词需要 100000 维向量。

造成：

- 存储浪费
- 计算复杂

问题 2：无法表示语义关系

One-hot 中：

$$\text{猫} = [1, 0, 0], \quad \text{狗} = [0, 1, 0]$$

计算余弦相似度：

$$\cos(\theta) = \frac{x \cdot y}{\|x\| \|y\|}$$

得到：

$$\cos(\theta) = 0$$

计算机认为：

猫 和 狗 没有任何关系

但是现实中：

猫 和 狗 都属于动物

因此需要一种能够保存语义关系的方法。

2.2 嵌入的核心思想

嵌入希望满足：

在原始空间中相似的对象，在向量空间中距离也相近。

即：如果

$$\text{sim}(x_i, x_j) \uparrow$$

希望：

$$\text{distance}(f(x_i), f(x_j)) \downarrow$$

常用距离 / 相似度度量：

欧氏距离：

$$d(x, y) = \sqrt{\sum_{i=1}^d (x_i - y_i)^2}$$

余弦相似度：

$$\cos(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2}$$

例如：

猫： [0.23, 0.56, 0.12]

狗： [0.21, 0.54, 0.10]

汽车： [-0.8, 0.2, 0.7]

计算：

$$\cos(\text{猫}, \text{狗}) > \cos(\text{猫}, \text{汽车})$$

因此：

猫 $\approx$ 狗

猫 $\neq$ 汽车

3. 嵌入的原理

嵌入的核心思想是：

通过学习一个映射函数，使向量空间保存数据之间的重要关系。

3.1 Word Embedding 原理

以自然语言处理中的词嵌入为例。

假设一句话：

The cat drinks milk

我们希望学习：

$$Embedding(cat)$$

核心假设：

一个词的含义可以由它周围出现的词决定。

即：

$$P(context \mid word)$$

例如：

cat 附近词：

- animal
- milk
- eat
- small

这些上下文信息决定：

$$vector(cat)$$

3.2 Word2Vec 模型

Word2Vec 主要有两种：

(1) CBOW 模型

Continuous Bag Of Words：通过上下文预测中心词。

例如：

I love eating ____

预测：

apple

数学目标——最大化：

$$P(w_t \mid w_{t-k}, \dots, w_{t+k})$$

损失函数：

$$L = - \sum_t \log P(w_t \mid context)$$

其中：

$$P(w_t \mid context) = \frac{e^{v_{w_t}^T h}}{\sum_i e^{v_i^T h}}$$

(2) Skip-Gram 模型

通过中心词预测上下文。

例如，输入：

king

预测：

queen

man

royal

优化目标：

$$\max \sum_t \sum_{j=-k}^k \log P(w_{t+j} \mid w_t)$$

3.3 神经网络中的 Embedding 层

在深度学习中，Embedding 本质上是一个矩阵：

$$E \in \mathbb{R}^{n \times d}$$

其中：

- n : 类别数量
- d : 嵌入维度

例如，10000 个单词：

$$E \in \mathbb{R}^{10000 \times 300}$$

第 100 个词：

$$embedding(w_{100}) = E_{100}$$

训练过程中，不断更新：

$$E = E - \eta \nabla L(E)$$

最终得到具有语义信息的向量。

4. 嵌入的应用

4.1 自然语言处理（NLP）——搜索引擎

传统搜索使用关键词匹配：

查询：汽车维修

文档：车辆保养方法

关键词不同 → 无法匹配。

使用 Embedding 后，将查询和文档分别转换：

$$q = f(\text{"汽车维修"}), \quad d = f(\text{"车辆保养方法"})$$

计算相似度：

$$similarity(q, d) = \frac{q^T d}{\|q\| \|d\|}$$

如果：

$$similarity > 0.8$$

认为：

汽车维修 $\approx$ 车辆保养

从而实现**语义搜索**。

4.2 推荐系统

例如，用户喜欢：

篮球
足球
NBA

系统学习用户向量：

$$u = [0.3, 0.8, 0.2]$$

商品"篮球鞋"的向量：

$$v = [0.35, 0.75, 0.18]$$

计算匹配分数：

$$score = u^T v$$

如果 $score$ 较高，则推荐篮球鞋。

4.3 图神经网络

对于社交网络，节点集合：

$$V = \{v_1, v_2, \dots, v_n\}$$

目标：学习

$$f(v_i) \in \mathbb{R}^d$$

使连接的节点距离更近：

$$\|f(v_i) - f(v_j)\| \rightarrow 0$$

例如好友推荐：

A 认识 B
B 认识 C
则 A 可能认识 C

4.4 图像 Embedding

深度神经网络：输入图像，经过 CNN 得到向量：

$$z = f(\text{Image})$$

例如：

猫图片 $\rightarrow [0.21, 0.45, 0.67, \dots]$

狗图片 $\rightarrow [0.20, 0.42, 0.65, \dots]$

相似图片距离较小。

应用：

- 人脸识别
- 图像搜索
- OCR

5. 现代大模型中的 Embedding

大型语言模型（LLM，如 Transformer）首先将文本转换为 token：

$$\text{text} \rightarrow \text{token}$$

然后：

$$\text{token} \rightarrow \text{embedding}$$

例如输入：

机器学习

转换：

$$x = [0.12, 0.56, \dots, 0.91]$$

Embedding 作为 Transformer 的输入，进入注意力机制：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V$$

模型通过大量训练学习：

- 词义
- 上下文关系
- 世界知识

6. 嵌入的优点与局限

6.1 优点

(1) 降低维度

原始 100000 维 One-hot → 嵌入 300 维，大大降低计算成本。

(2) 保存语义信息

向量空间满足：

$$king - queen \approx man - woman$$

即：

$$v_{king} - v_{queen} \approx v_{man} - v_{woman}$$

表示"性别关系"。

(3) 支持机器学习计算

距离 $\|x - y\|$ 、相似度 $x^T y$ 均可直接计算。

6.2 局限

(1) 解释性较弱

例如：

$$x_{100} = 0.327$$

很难解释"0.327 代表什么"。

(2) 依赖训练数据

如果训练数据存在偏见，Embedding 也会学习偏见。