

前置知识二：通信复杂度（Communication Complexity）

1. 定义

两个或多个计算主体在协同完成某个计算任务时，最少需要交换多少信息。

它关注的不是计算量（Computational Complexity），而是**通信成本（Communication Cost）**。

经典模型中，有两个参与者：

- Alice：拥有输入数据 x
- Bob：拥有输入数据 y

二者希望共同计算一个函数：

$$f(x, y)$$

但是：

- Alice 不知道 y
- Bob 不知道 x

他们只能通过发送消息进行交流。

通信复杂度定义为：

$$C(f) = \min_{\Pi} \max_{x, y} |\Pi(x, y)|$$

其中：

- $C(f)$ ：计算函数 f 所需的最小通信量
- Π ：一种通信协议（Protocol）
- $|\Pi(x, y)|$ ：协议执行过程中交换的比特数

简单来说：

通信复杂度就是解决一个问题时，最少需要传输多少 bit 的数据。

2. 基本模型

2.1 确定性通信复杂度 (Deterministic Communication Complexity)

在确定性模型中：

- 通信协议完全固定
- 相同输入一定产生相同通信过程

例如：

Alice 和 Bob 判断两个字符串是否相同：

$$EQ(x, y) = \begin{cases} 1, & x = y \\ 0, & x \neq y \end{cases}$$

如果 Alice 直接发送整个字符串：

$$x \rightarrow Bob$$

通信量为：

$$C(EQ) = n$$

其中：

- n ：字符串长度

但是如果设计更好的协议，可以减少通信。

2.2 随机通信复杂度 (Randomized Communication Complexity)

现实中经常允许使用随机算法。

协议加入随机变量：

$$R$$

计算：

$$f(x, y, R)$$

允许一定错误概率：

$$P[f(x, y, R) \neq f(x, y)] \leq \epsilon$$

其中：

- ϵ ：错误概率

通常：

$$\epsilon < \frac{1}{3}$$

即可认为可靠。

随机通信复杂度表示为：

$$R(f)$$

3. 通信复杂度原理（为什么需要研究）

3.1 数据不能无限传输

在分布式系统中：

- 数据规模越来越大
- 网络带宽有限

例如：

一个机器学习模型：

$$W \in \mathbb{R}^{10^9}$$

参数数量：

$$10^9$$

如果每个参数占 32 bit：

$$10^9 \times 32$$

需要：

$$3.2 \times 10^{10} \text{ bit}$$

约：

4 GB

直接传输成本巨大。

因此需要研究：

能否只发送少量信息，同时完成计算？

3.2 信息理论限制

通信复杂度的核心思想：一个消息包含的信息量有限。

根据香农信息理论：如果一个随机变量有 N 种可能，至少需要：

$$\log_2 N$$

个 bit 表示。

例如：

Alice 有一个数字：

$$x \in \{1, 2, \dots, 2^n\}$$

为了让 Bob 完全知道 x ，至少需要：

$$\log_2(2^n) = n$$

bit。

因此：

$$C(f) \geq \text{信息下界}$$

4. 经典问题：Equality Problem

4.1 问题定义

Alice 有：

$$x \in \{0, 1\}^n$$

Bob 有：

$$y \in \{0, 1\}^n$$

要求判断：

$$EQ(x, y)$$

4.2 直接方法

Alice 发送：

$$x$$

通信 n bit，因此：

$$C(EQ) \leq n$$

4.3 随机方法：哈希

选择随机哈希函数：

$$h : \{0, 1\}^n \rightarrow \{0, 1\}^k$$

Alice 发送：

$$h(x)$$

Bob 计算：

$$h(y)$$

比较：

$$h(x) = h(y)$$

如果：

$$x = y$$

一定成功。

如果：

$$x \neq y$$

碰撞概率：

$$P[h(x) = h(y)] = 2^{-k}$$

因此只需要：

$$k = \log_2 \frac{1}{\epsilon}$$

通信复杂度：

$$C(EQ) = O\left(\log \frac{1}{\epsilon}\right)$$

相比 $O(n)$ 大幅降低。

5. 通信复杂度应用

5.1 分布式机器学习

在联邦学习 (Federated Learning) 中，多个客户端：

$$C_1, C_2, \dots, C_n$$

拥有本地数据：

$$D_1, D_2, \dots, D_n$$

目标：训练模型 w ，更新：

$$w_{t+1} = w_t - \eta \nabla L(w_t)$$

如果每轮直接发送梯度：

$$\nabla L(w)$$

通信量巨大。

因此采用**梯度压缩**，例如随机量化：

$$Q(g)$$

满足：

$$E[Q(g)] = g$$

降低通信：

$$O(d) \rightarrow O(k)$$

其中：

- d ：梯度维度
- k ：压缩后维度

5.2 数据库查询优化

分布式数据库中，两个节点：

$$A, B$$

执行连接：

$$R \bowtie S$$

如果直接传输：

$$|R| + |S|$$

数据量巨大。

通信复杂度思想：减少传输数据。例如先发送哈希摘要：

$$H(R)$$

再过滤：

$$S'$$

从而降低通信量 (Communication) 。

5.3 图计算

大型图：

$$G = (V, E)$$

可能分布在多个服务器。

计算 PageRank 时需要交换节点信息：

$$PR(v)$$

通信复杂度决定：

- 网络压力
- 计算速度
- 系统扩展能力