

论文 Review: Tight Lower Bounds for the Distinct Elements Problem

瞿池伟 张天驰

2026 年 7 月 29 日

摘要

目录

1	论文概览	3
1.1	论文基本信息	3
1.2	解决的问题	3
1.3	主要结果概述	3
1.4	本 Review 的组织结构	4
2	问题背景与动机	4
2.1	数据流模型	4
2.2	Distinct Elements 问题 (F_0 估计)	4
2.3	应用动机	4
2.4	为什么研究空间下界	4
3	相关工作	4
3.1	上界: F_0 估计算法的发展	6
3.2	本文之前的空间下界	6
3.3	相关的通信复杂性工作	7
3.4	本文发表之后的新进展	7
4	论文的技术贡献	8
4.1	主要定理	8
4.2	证明路线图	8
4.3	技术直觉	8
4.4	与先前下界技术的对比	8

5	技术细节与证明	8
5.1	预备知识：单向通信复杂性与 Yao 极小极大原则	8
5.2	VC 维与 Shatter Coefficients	9
5.3	$\Pi_{l_2}(t)$ 问题的单向通信复杂度下界	10
5.4	$l_2 \rightarrow l_1$ 低畸变嵌入	11
5.5	从 $\Pi_{l_2}(t)$ 到 F_0 的约化	11
5.6	主定理的整合与参数范围	13
6	正确性与优越性分析	14
6.1	证明正确性的检验	14
6.2	紧性分析：下界与上界的匹配程度	14
6.3	遗留问题及其后续解决	14
7	评价与讨论	14
7.1	论文的非凡之处	14
7.2	局限与批评	15
7.3	对后续研究的影响	16
7.4	本组的理解过程与心得（可选）	16
8	总结	16

1 论文概览

1.1 论文基本信息

本论文 [1] 题为 *Tight Lower Bounds for the Distinct Elements Problem*, 作者为 Piotr Indyk 与 David Woodruff, 两人当时均任职于美国麻省理工学院 (MIT) 计算机科学与人工智能实验室 (CSAIL 前身, Theory Group)。论文发表于第 44 届 IEEE 计算机科学基础年会 (44th Annual IEEE Symposium on Foundations of Computer Science, FOCS 2003)。FOCS 与 STOC 并称理论计算机科学领域的两大顶级会议, 在算法与复杂性理论方向具有最高的学术影响力。Indyk 是数据流算法与降维 (locality-sensitive hashing、低畸变嵌入) 方向的知名学者, Woodruff 当时为 MIT 博士研究生, 其后在数据流与线性代数算法方向做出了一系列奠基性工作。两位作者的组合恰好对应了本文技术的两大支柱: 几何嵌入与通信复杂性下界。

1.2 解决的问题

一句话概括: 本文证明了在单趟数据流模型下, (ϵ, δ) -近似不同元素个数 F_0 所需空间的紧下界 $\Omega(1/\epsilon^2)$, 将该问题的下界从已知的 $\Omega(1/\epsilon)$ 提升到与上界基本匹配的水平。

具体而言, 论文研究的是数据流 (streaming) 模型中的经典问题: 给定来自大小为 m 的全集 $[m] = \{0, 1, \dots, m-1\}$ 的一个元素流 $a = a_1, \dots, a_n$ (元素按对抗性顺序到达, 算法只能单趟扫描), 估计流中不同元素的个数 $F_0 = F_0(a)$ 。由于存在 $\Omega(m)$ 的确定性空间下界, 精确计算甚至确定性近似都不可行, 因此研究界转而寻求随机化近似算法: 称算法 $\mathcal{A}$ 是 F_0 的 (ϵ, δ) -近似, 若其输出 $\tilde{F}_0$ 满足 $\Pr[|\tilde{F}_0 - F_0| > \epsilon F_0] < \delta$ 。

在本文之前, 已知的最好算法 (Bar-Yossef 等人, RANDOM 2002) 使用 $O(((1/\epsilon)^2 \log \log m + \log m \cdot \log(1/\epsilon)) \log(1/\delta))$ 的空间, 而最好的空间下界只有 $\Omega(1/\epsilon)$ (基于 ϵ -set disjointness 问题的单向通信复杂度) 以及更早的 $\Omega(\log m)$ 。上界中主导项 $1/\epsilon^2$ 与下界 $1/\epsilon$ 之间存在一个二次方的鸿沟, “还能不能做得更好” 这一根本问题悬而未决。本文正是回答了这一问题。

1.3 主要结果概述

本文的主要结果可非正式地陈述如下 (正式定理陈述见第 4 节):

- **空间下界:** 任何单趟 (ϵ, δ) -近似 F_0 的数据流算法 (δ 为常数), 当 $\epsilon = \Omega(m^{-1/(9+k)})$ 时 ($k > 0$ 为任意常数), 必须使用 $\Omega(1/\epsilon^2)$ 位的空间。这把此前该参数范围内的 $\Omega(1/\epsilon)$ 下界提升了整整一个 $1/\epsilon$ 因子。
- **紧性:** 该下界与当时最优上界几乎匹配——对小 ϵ 仅相差 $\log \log m$ 因子, 对大 ϵ 仅相差 $\log(1/\epsilon)$ 因子。换言之, F_0 估计问题的空间复杂度关于 ϵ 的依赖被本文 (在相差低阶因子的意义下) 最终刻画为 $\Theta(1/\epsilon^2)$ 。
- **技术贡献:** 下界通过一条新颖的约化链获得——从欧氏空间中一个布尔 promise 问题 $\Pi_{l_2}(t)$ (Alice 持单位范数向量 x , Bob 持标准基向量 y , 需区分内积 $\langle x, y \rangle = 0$ 与 $\langle x, y \rangle = 1/\sqrt{t}$) 的单向通信复杂度下界 $\Omega(t)$ 出发, 借助 VC 维/shatter coefficient 的信息论工具 (Kremer–Nisan–Ron 定理及其推广) 建立通信下界, 再经由 Indyk 的 $l_2 \rightarrow l_1$ 低畸变嵌入 (stable distributions 方法), 通过有理近似、通分放大与一元编码将嵌入后的向量转化为比特串, 最终把比特串视为流的特征向量 (F_0 恰为其 Hamming 重量) 完成约化。这一“欧氏问题 $\rightarrow$ 嵌入 $\rightarrow$ 汉明空间 $\rightarrow$ 数据流”的路线是本文的方法论创新, 突破了此前基于集合不交

性 (set disjointness) 的约化只能给出 $\Omega(1/\varepsilon)$ 的瓶颈。

值得注意的是, 本文发表后不久, Kane–Nelson–Woodruff (PODS 2010) 给出了空间 $O(1/\varepsilon^2 + \log m)$ 的最优算法, Woodruff (2004) 也直接改进了 Hamming 空间中的下界构造, 最终使 F_0 估计问题的空间复杂度被完全刻画。本文是这条故事线中确立 $1/\varepsilon^2$ 这一正确量级的主角。

1.4 本 Review 的组织结构

本 Review 其余部分组织如下:

- **第 2 节 (问题背景与动机):** 形式化数据流模型与 F_0 的 (ε, δ) -近似定义, 说明确定性算法的 $\Omega(m)$ 下界, 介绍数据库查询优化、网络流量统计与 DoS 攻击检测等应用, 并解释研究空间下界的意义。
- **第 3 节 (相关工作):** 沿三条线索梳理文献—— F_0 估计算法的发展 (Flajolet–Martin、Alon–Matias–Szegedy、Bar-Yossef 等人)、本文之前的空间下界 ($\Omega(\log m)$ 与 $\Omega(1/\varepsilon)$)、通信复杂性与信息论工具的相关工作, 以及本文发表之后的新进展。
- **第 4 节 (论文的技术贡献):** 给出主要定理的正式陈述与参数适用范围, 画出证明路线图, 解释技术直觉, 并与先前 $\Omega(1/\varepsilon)$ 下界技术对比。
- **第 5 节 (技术细节与证明):** 按“定义—引理—证明—备注”的方式完整展开证明链: 单向通信复杂性与 Yao 极小极大原则、VC 维与 shatter coefficients、 $\Pi_{l_2}(t)$ 的 $\Omega(t)$ 通信下界、 $l_2 \rightarrow l_1$ 低畸变嵌入、从 $\Pi_{l_2}(t)$ 到 F_0 的三步约化, 以及主定理的整合。
- **第 6 节 (正确性与优越性分析):** 记录我们对关键步骤的独立复核, 分析下界与上界的匹配程度 (tightness), 讨论遗留 gap 的后续解决。
- **第 7 节 (评价与讨论):** 给出本组对论文创新点、局限性与历史影响的独立评价。
- **第 8 节 (总结):** 浓缩全文, 概括问题、技术、结论与总体评价。

2 问题背景与动机

2.1 数据流模型

2.2 Distinct Elements 问题 (F_0 估计)

2.3 应用动机

2.4 为什么研究空间下界

3 相关工作

本节沿三条线索组织文献: 第 3.1 节梳理 F_0 估计算法 (上界) 的发展, 第 3.2 节回顾本文之前的空间下界, 第 3.3 节介绍本文所用的通信复杂性与嵌入工具的来源, 第 3.4 节讨论本文发表之后的新进展。表 1 给出一个时间线总览。

需要说明的是检索渠道: 论文自身引用的文献 ([2, 3, 4, 5, 8, 9, 7, 10, 11, 13] 等) 以其参考文献表为准; 论文未提及的工作——包括 Gibbons–Tirthapura [14]、Durand–Flajolet [15]、HyperLogLog [16]、Gap-Hamming 下界系列 [17, 18, 19]、Kane–Nelson–Woodruff [20]、Jayram–Woodruff [21]、Błasiok [22] 等——由本组通过 DBLP 与 Google Scholar 检索定位, 并以 arXiv 全文及 ACM Digital Library 记录核实其发表年份、会议与主要结论。

表 1 F_0 估计问题的研究时间线（上界、下界与工具三条线索）

年份	文献	类型	主要结果
1985	Flajolet–Martin [2]	上界	首个概率计数算法，寄存器仅 $O(\log m)$ 位
1996/99	Alon–Matias–Szegedy [3]	上界/下界	频率矩框架；确定性 $\Omega(m)$ 、随机化 $\Omega(\log m)$ 下界
2001	Gibbons–Tirthapura [14]	上界	并流上的 F_0 估计， $\tilde{O}(1/\varepsilon^2)$ 空间
2002	Bar-Yossef et al. [4]	上界	本文之前最优： $O((1/\varepsilon^2 \log \log m + \log m \log \frac{1}{\varepsilon}) \log \frac{1}{\delta})$
2002	Bar-Yossef [5]	下界	经 ε -set disjointness 得 $\Omega(1/\varepsilon)$
1977	Yao [6]	工具	极小极大原则：随机下界 $\Leftarrow$ 分布下确定性下界
1999	Kremer–Nisan–Ron [8]	工具	单向随机通信复杂度 $\geq$ VC 维（相差熵因子）
2002	Bar-Yossef et al. [9]	工具	shatter coefficient 推广，信息论方法
1977	Figiel et al. [10]	工具	$l_2 \rightarrow l_1$ 低畸变嵌入的存在性
2000	Indyk [11]	工具	stable distributions 草图， l_p 范数流计算
2003	Indyk–Woodruff（本文）	下界	$\varepsilon = \Omega(m^{-1/(9+k)})$ 时 $\Omega(1/\varepsilon^2)$
2003	Durand–Flajolet [15]	上界	LogLog 计数，实用化路线的起点
2004	Woodruff [13]	下界	直接在 Hamming 空间构造， $\Omega(1/\varepsilon^2)$ 适用全参数范围
2007	Flajolet et al. [16]	上界	HyperLogLog，工业界标准基数估计算法
2008	Jayram et al. [17]	下界	单向 Hamming 距离通信复杂度 $\Omega(n)$
2009	Brody–Chakrabarti [18]	下界	Gap-Hamming 多轮通信下界
2010	Kane–Nelson–Woodruff [20]	上界	最优算法： $O(1/\varepsilon^2 + \log m)$ （ δ 为常数）
2011	Chakrabarti–Regev [19]	下界	Gap-Hamming 最优 $\Omega(n)$ 随机通信下界（轮数不限）
2011/13	Jayram–Woodruff [21]	下界	$\Omega(\varepsilon^{-2} \log(1/\delta))$ ，刻画 δ 依赖
2018	Błasiok [22]	上界	$O(\varepsilon^{-2} \log(1/\delta) + \log m)$ ，三参数均最优

3.1 上界： F_0 估计算法的发展

F_0 估计（数据库界常称基数估计，cardinality estimation）是数据流模型中研究历史最悠久的问题之一。Flajolet 与 Martin [2]（会议版 1983，期刊版 1985）提出了首个概率计数算法：将每个流元素哈希为均匀随机串，用位图记录哈希值二进制表示中最低位 1 的位置分布；由于随机串中低位连续 0 的长度服从几何分布，最大观测值隐含了不同元素个数的量级信息。该算法每个寄存器只需 $O(\log m)$ 位，多开 R 个寄存器可将相对误差压到约 $1/\sqrt{R}$ ，开创了“用对数级空间换取近似精度”的范式。

Alon、Matias 与 Szegedy [3]（STOC 1996，期刊版 JCSS 1999）系统建立了频率矩（frequency moments） F_k 的流式估计框架。对 F_0 ，他们给出基于随机哈希的 $\text{poly}(1/\varepsilon, \log m)$ 空间算法，同时证明了确定性计算或确定性 $(1 \pm \varepsilon)$ 近似 F_0 需要 $\Omega(m)$ 空间，从而从根本上确立了随机化近似的必要性；此外他们通过将相等性判定问题 EQ 的单向通信复杂度（ $\Theta(\log m)$ ）约化到 F_0 ，得到随机化算法的 $\Omega(\log m)$ 空间下界。这篇论文获 2005 年 Gödel 奖，是数据流算法领域的奠基之作。

此后算法沿两个方向改进。Gibbons 与 Tirthapura [14]（SPAA 2001）基于 distinct sampling 思想，估计多条流之并上的 F_0 等简单函数，空间为 $\tilde{O}(1/\varepsilon^2 \cdot \log m)$ 量级。本文发表之前的最优结果属于 Bar-Yossef、Jayram、Kumar、Sivakumar 与 Trevisan [4]（RANDOM 2002），其算法空间为

$$O\left(\left(\frac{1}{\varepsilon^2} \log \log m + \log m \cdot \log \frac{1}{\varepsilon}\right) \log \frac{1}{\delta}\right),$$

当 δ 为常数时主导项是 $1/\varepsilon^2$ 。正是这个 $1/\varepsilon^2$ 项引出了本文的核心问题：这究竟是算法设计的巧合，还是问题固有的复杂度？

3.2 本文之前的空间下界

与繁荣的上界工作相比，本文之前的下界相当薄弱，只有两条：

$\Omega(\log m)$ 下界（AMS [3]）。思路是将两人单向通信复杂性的相等性问题 EQ（Alice 与 Bob 各持一个 m 位串，判定是否相等，随机化单向通信复杂度为 $\Theta(\log m)$ ）约化为 F_0 计算：Alice 用自己的串作为流的特征向量喂入 F_0 算法，把算法内部状态传给 Bob，Bob 继续喂入自己的串；拼接流的 F_0 值即可判定两串是否相等。因此 F_0 算法的空间至少为 $\Omega(\log m)$ 。这个约化建立了“流算法空间 $\geq$ 通信复杂度”的基本范式，本文与后续所有下界工作都沿用这一范式，只是更换了更精细的通信问题。

$\Omega(1/\varepsilon)$ 下界（Bar-Yossef 博士论文 [5]）。为了得到依赖 ε 的下界，Bar-Yossef 使用 ε -set disjointness 问题：Alice 持有 $x \subseteq [m]$ ， $|x| = m/2$ ；Bob 持有 $y \subseteq [m]$ ， $|y| = \varepsilon m$ ；并承诺要么 $y \subseteq x$ ，要么 $y \cap x = \emptyset$ 。两种情形下拼接流的 F_0 分别为 $m/2$ 与 $m/2 + \varepsilon m$ ，相差恰为相对误差 ε 可分辨的间隙，故 (ε, δ) -近似 F_0 的算法可区分两种情形，继承该通信问题的 $\Omega(1/\varepsilon)$ 单向通信下界。

然而这个约化是“弱”的：它并没有用到 F_0 算法的全部能力。Alice 完全可以不运行 F_0 算法，而是随机采样 $O(1/\varepsilon)$ 个全集元素、检查它们是否属于 x 并把结果发给 Bob——Bob 据此同样能以高概率判定承诺情形。换言之， ε -set disjointness 本身有一个 $O(1/\varepsilon)$ 的直接协议，其通信复杂度上界就是 $O(1/\varepsilon)$ ，用它做约化源永远不可能导出超过 $\Omega(1/\varepsilon)$ 的下界。要突破 $1/\varepsilon$ ，必

须寻找一个“只有 F_0 算法才能高效求解”的 promise 问题——这正是本文选取欧氏空间内积判定问题 $\Pi_{l_2}(t)$ 的动机，详见第 4 节。

3.3 相关的通信复杂性工作

本文证明链所用的工具各有出处，本节简述其来源与在本文中的角色。

Yao 极小极大原则 [6]。 Yao (FOCS 1977) 的经典结果表明：随机算法在最坏输入上的复杂度下界，等于某输入分布下确定性算法在该分布上的复杂度下界（取所有分布中的最大值）。在本文中，它允许作者把“随机化单向协议的通信下界”转化为“某一精心构造的输入分布 μ 下确定性协议的分布通信复杂度 $D^{\mu,\delta}$ 的下界”，从而可以使用信息论工具。

VC 维与单向通信复杂度 (Kremer–Nisan–Ron [8])。 VC 维的概念源于 Vapnik 与 Chervonenkis [7] (1971) 关于经验过程一致收敛的工作，是学习理论的核心概念。Kremer、Nisan 与 Ron [8] (Computational Complexity 1999) 首次建立其与随机化单向通信复杂度的联系：对任意布尔函数 $f: X \times Y \rightarrow \{0,1\}$ ，存在输入分布 μ 使得 $D^{\mu,\delta}(f) \geq \ell(1 - H_2(\delta))$ ，其中 ℓ 是函数族 f 的 VC 维。即“函数族越丰富 (VC 维越大)，单向通信越贵”。

Shatter coefficient 推广 (Bar-Yossef et al. [9])。 当 VC 维难以直接计算时，Bar-Yossef、Jayram、Kumar 与 Sivakumar [9] (CCC 2002) 的信息论方法给出更灵活的版本：对任意 $\ell \geq \text{VCD}$ ， $D^{\mu,\delta}(f) \geq (\log \text{SC}(f, \ell) - \ell \cdot H_2(\delta))/2$ 。本文对 $\Pi_{l_2}(t)$ 的 VC 维没有好办法直接算，正是靠构造一个大小为 $\Theta(t)$ 、shatter coefficient 接近 $2^{\Theta(t)}$ 的点集应用此定理，才拿到 $\Omega(t)$ 的通信下界（第 5 节详述）。

$l_2 \rightarrow l_1$ 低畸变嵌入 (Figiel et al. [10]; Indyk [11])。 嵌入定理本身来自 Banach 空间几何：Figiel、Lindenstrauss 与 Milman [10] (Acta Mathematica 1977) 证明了对任意 γ ，存在 $(1 + \gamma)$ -畸变嵌入 $\phi: l_2^t \rightarrow l_1^d$ ， $d = O(t \log(1/\gamma)/\gamma^2)$ 。Indyk [11] (FOCS 2000，期刊版 JACM 2006) 基于 stable distributions (p -稳定分布) 给出了这类嵌入的显式随机化构造，并开创了其在 l_p 范数数据流计算中的应用；他在 FOCS 2001 的特邀报告 [12] 系统总结了低畸变嵌入的算法应用。本文把这条嵌入链用作“几何问题 $\rightarrow$ 汉明空间 $\rightarrow$ 数据流”约化中的关键桥梁。

3.4 本文发表之后的新进展

本文发表后，围绕 F_0 的上界、下界与应用三条线都迅速推进，最终在 2018 年前后使该问题的空间复杂度在所有参数维度上被完全刻画。

下界的完善。 Woodruff [13] (SODA 2004，即本文参考文献 [11]) 放弃了“先嵌入到 l_1 再到 Hamming 空间”的间接路线（该路线使维度膨胀多项式因子，导致本文的 ε 适用范围只有 $\Omega(m^{-1/(9+k)})$ ），改为直接在 Hamming 空间用精细的概率方法构造向量集，对所有频率矩得到最优空间下界；对 F_0 而言这把 $\Omega(1/\varepsilon^2)$ 的适用范围从 $\varepsilon = \Omega(m^{-1/(9+k)})$ 大幅拓宽。

本文另一个影响深远的遗产是 Gap-Hamming-Distance (GHD) 通信问题——判定两比特串的汉明距离是 $\geq n/2 + \sqrt{n}$ 还是 $\leq n/2 - \sqrt{n}$ ，由本文正式提出。它迅速成为数据流下界的标准约化源：Jayram、Kumar 与 Sivakumar [17] (Theory of Computing 2008) 证明了其单向版本

(Hamming 距离判定) 的 $\Omega(n)$ 下界; Brody 与 Chakrabarti [18] (CCC 2009) 将其推进到受限多轮协议; Chakrabarti 与 Regev [19] (STOC 2011, 期刊版 SICOMP 2012) 最终证明了任意轮数随机协议的 $\Omega(n)$ 最优下界, 彻底解决了本文留下的猜想。由 GHD 到 F_0 的约化随即给出适用于全部参数范围、且对多趟扫描也成立的 $\Omega(1/\varepsilon^2)$ 空间下界。Jayram 与 Woodruff [21] (SODA 2011, 期刊版 ACM TALG 2013) 进一步把对误差概率 δ 的依赖也纳入下界, 证明 $\Omega(\varepsilon^{-2} \log(1/\delta))$, 说明“ $\log(1/\delta)$ 倍独立重复”这一朴素做法在渐近意义下不可改进。

最优算法的出现。 上界方面, Kane、Nelson 与 Woodruff [20] (PODS 2010) 给出了空间 $O(1/\varepsilon^2 + \log m)$ 的算法 (δ 为常数), 与本文下界精确匹配, 首次证明 F_0 估计的空间复杂度就是 $\Theta(1/\varepsilon^2 + \log m)$ 。Błasiok [22] (SODA 2018, 期刊版 ACM TALG 2020) 把最优性推广到亚常数误差概率: 空间 $O(\varepsilon^{-2} \log(1/\delta) + \log m)$, 对 ε 、 δ 、 m 三个参数同时最优, 且支持 strong tracking (整个流过程中持续输出正确估计)。至此, 由本文确立 $1/\varepsilon^2$ 量级所开启的故事在上界一侧也宣告完结。

实用化与变体。 与应用社区并行的是实用算法的演进: Durand 与 Flajolet [15] (ESA 2003) 的 LogLog 计数与 Flajolet 等人 [16] (AofA 2007) 的 HyperLogLog 把 F_0 估计做到每个寄存器仅 $\log \log m$ 位, 成为 Redis、Presto 等工业系统中的标准组件; 与本文的理论结果对照可以看到, 工程界接受的常数因子与模型差异 (哈希视为随机预言、插入流) 正是理论最优结果允许的空间。此外 Woodruff [23] (ICDT 2009) 证明即使流元素按随机顺序到达 (平均情形), F_0 估计仍需 $\Omega(1/\varepsilon^2)$ 空间, 说明本文的困难性并非来自对抗性顺序的人为假设。2022 年 Chakraborty、Vinodchandran 与 Meel [24] (ESA 2022) 提出的 CVM 算法则以极简形式重新实现了最优空间, 被称为“可以写进教科书”的算法, 可视为这条研究线的教学化终点。

4 论文的技术贡献

4.1 主要定理

4.2 证明路线图

4.3 技术直觉

4.4 与先前下界技术的对比

5 技术细节与证明

本节完整展开论文的证明链。记二元熵函数 $H_2(p) = -p \log_2 p - (1-p) \log_2 (1-p)$; 对向量 v , $|v|$ 表示其 l_1 范数, $\|v\|$ 表示其 l_2 范数; 对比特串 x , $\text{wt}(x)$ 表示其中 1 的个数, $\Delta(x, y)$ 表示 x 与 y 的汉明距离。本节中的定理编号沿用论文原文编号 (论文 Theorem 3–6、Corollary 7、Claim 8), 以便读者对照原文核验。

5.1 预备知识: 单向通信复杂性与 Yao 极小极大原则

定义 1 (单向协议与通信复杂度; 论文 Definition 1) 设 $f: X \times Y \rightarrow \{0, 1\}$ 为布尔函数。Alice 持输入 $x \in X$, Bob 持输入 $y \in Y$ 。在**单向 (one-way)** 协议中, Alice 计算某个只依赖 x 的消息 $A(x)$ 发送给 Bob, Bob 根据 $A(x)$ 与 y 输出对 $f(x, y)$ 的猜测。协议 Π 的**通信代价**是所有

输入上 Alice 发送的最长消息的期望长度。 f 的 δ -误差随机化（单向）通信复杂度 $R^\delta(f)$ 是在所有输入上满足 $\Pr[\Pi(x, y) \neq f(x, y)] \leq \delta$ 的最优协议的通信代价。对输入分布 μ ， f 的 δ -误差 μ -分布通信复杂度 $D^{\mu, \delta}(f)$ 是在 μ 下误差不超过 δ 的最优确定性协议的通信代价。

定理 1 (Yao 极小极大原则 [6]) 对任意布尔函数 f 、误差 δ 与任意输入分布 μ ， $R^\delta(f) \geq D^{\mu, \delta}(f)$ 。

注 1 (为什么这条原则对本文至关重要) 随机化协议可以看作确定性协议分布上的一个随机变量：若每个确定性协议在某分布 μ 下都要付出高昂通信代价才能取得低误差，那么随机化协议（确定性协议的混合）在 μ 的某个输入上也不可能做得更好。因此，要证明随机化单向协议的下界，只需自由地设计一个难处理的输入分布 μ ，然后分析确定性协议在该分布下的表现——后者可以用信息论工具精确刻画。本文第 5.3 节正是沿此路线：先构造分布（通过 shatter coefficient 间接给出），再推出 $D^{\mu, \delta} = \Omega(t)$ 。

注 2 (从通信下界到流算法空间下界) 这是 AMS [3] 确立的标准范式：设 $\mathcal{A}$ 是空间为 S 的单趟 (ε, δ) -近似 F_0 算法。Alice 把自己的输入编码为一段流，在本地运行 $\mathcal{A}$ 后把算法的全部内部状态（至多 S 位）发给 Bob；Bob 把状态载入自己的 $\mathcal{A}$ 副本，继续处理自己输入对应的流段。若拼接流的 F_0 值能区分通信问题的两种承诺情形，则 $S \geq R^\delta(f)$ 。整条证明链的最终一环（第 5.5 节）就是这个范式的一次精细实例化。

5.2 VC 维与 Shatter Coefficients

定义 2 (Shatter coefficient 与 VC 维；论文 Definition 2) 设 $\mathcal{F} = \{f : X \rightarrow \{0, 1\}\}$ 是域 X 上的布尔函数族。对子集 $S \subseteq X$ ，其 **shatter coefficient** 为 $\text{SC}(\mathcal{F}|_S) = |\{f|_S\}_{f \in \mathcal{F}}|$ ，即把 $\mathcal{F}$ 中函数限制到 S 上所能得到的不同比特模式数。第 ℓ 个 shatter coefficient $\text{SC}(\mathcal{F}, \ell)$ 是所有大小为 ℓ 的子集上该数量的最大值。若 $\text{SC}(\mathcal{F}|_S) = 2^{|S|}$ ，称 S 被 $\mathcal{F}$ 打散 (shattered)； $\mathcal{F}$ 的 **VC 维** $\text{VCD}(\mathcal{F})$ 是能被打散的最大子集的大小。

定理 2 (Kremer–Nisan–Ron [8]；论文 Theorem 3) 对任意 $f : X \times Y \rightarrow \{0, 1\}$ 与任意 $0 < \delta < 1$ ，存在 $X \times Y$ 上的分布 μ 使得

$$D^{\mu, \delta}(f) \geq \ell(1 - H_2(\delta)), \quad \ell = \text{VCD}(f_X),$$

其中 $f_X = \{f_x : Y \rightarrow \{0, 1\} \mid x \in X\}$ ， $f_x(y) = f(x, y)$ 。

定理 3 (Bar-Yossef et al. [9]；论文 Theorem 4) 对任意 $f : X \times Y \rightarrow \{0, 1\}$ 、任意 $\ell \geq \text{VCD}(f_X)$ 与任意 $\delta > 0$ ，存在分布 μ 使得

$$D^{\mu, \delta}(f) \geq \frac{\log \text{SC}(f_X, \ell) - \ell \cdot H_2(\delta)}{2}.$$

注 3 (工具的角色) 直觉是：单向协议中 Bob 只能依靠 Alice 的消息区分不同的 x ；若函数族 f_X 在某个大小为 ℓ 的 y -集合上能产生 $2^{\Omega(\ell)}$ 种不同的真值模式，那么 Alice 的消息必须编码 $\Omega(\ell)$ 位信息才能让 Bob 以低误差输出正确模式——熵因子 $H_2(\delta)$ 是允许 δ 误差带来的折扣。论文 Theorem 3 要求算出 VC 维，而本文面对的函数族（欧氏内积判定）VC 维难以直接计算；

Theorem 4 允许用任意 $\ell \geq \text{VCD}$ 配上 shatter coefficient 的下界，只要构造出“模式足够多”的点集即可，这正是第 5.3 节的打法。

5.3 $\Pi_{l_2}(t)$ 问题的单向通信复杂度下界

固定 ε ，令 $t = t(\varepsilon) = \Theta(1/\varepsilon^2)$ （不妨设 t 为 2 的幂）。

定义 3 ($\Pi_{l_2}(t)$ ；论文第 3.1 节) 令 $E = \{e_1, \dots, e_t\}$ 为 $\mathbb{R}^t$ 的标准基。先定义

$$\Pi'_{l_2}(t) = \{(x, y) \in [0, 1]^t \times E \mid \|x\| = 1, \langle x, y \rangle = 0 \text{ 或 } \langle x, y \rangle = 2/\sqrt{t}\}.$$

为使坐标可被有限描述且能赋予概率分布，将有理数 p/q 的尺寸定义为 $\lceil \log_2 p \rceil + \lceil \log_2 q \rceil + 1$ ，并设 $B = \lceil 2 \log t \rceil$ 。定义

$$\Pi_{l_2}(t) = \{(x, y) \in \Pi'_{l_2}(t) \mid \forall i, x_i, y_i \text{ 为尺寸 } \leq B \text{ 的有理数}\}.$$

令 X, Y 分别为可出现于合法输入对中的 x, y 之集合。对 $(x, y) \in \Pi_{l_2}(t)$ ，定义 $f(x, y) = 0$ 若 $\langle x, y \rangle = 0$ ， $f(x, y) = 1$ 若 $\langle x, y \rangle = 2/\sqrt{t}$ 。函数族为 $\mathcal{F} = f_X = \{f_x : Y \rightarrow \{0, 1\} \mid x \in X\}$ 。

引理 1 (内积间隙 $\Rightarrow$ 距离间隙；论文第 3.1 节末) 对 $(x, y) \in \Pi_{l_2}(t)$ ：

$$f(x, y) = 0 \Rightarrow \|y - x\| = \sqrt{2}, \quad f(x, y) = 1 \Rightarrow \|y - x\| < \sqrt{2} \left(1 - \frac{1}{\sqrt{t}}\right).$$

证明. 由 $\|y - x\|^2 = \|y\|^2 + \|x\|^2 - 2\langle x, y \rangle$ 及 $\|x\| = \|y\| = 1$ ：当 $f(x, y) = 0$ 时 $\|y - x\|^2 = 2$ ；当 $f(x, y) = 1$ 时 $\|y - x\|^2 = 2 - 4/\sqrt{t}$ ，于是 $\|y - x\| = \sqrt{2}\sqrt{1 - 2/\sqrt{t}} < \sqrt{2}(1 - 1/\sqrt{t})$ ，最后一步用到 $\sqrt{1 - u} < 1 - u/2$ ($0 < u < 1$)。□

这条引理是整条约化的支点：内积的 $2/\sqrt{t}$ 间隙被转化为 l_2 距离的 $(1 - 1/\sqrt{t})$ 相对间隙，而距离（而非内积）才能经嵌入与编码一路传递到 F_0 。

定理 4 (论文 Theorem 6) $\mathcal{F}$ 的第 $t/4$ 个 shatter coefficient 满足 $\text{SC}(\mathcal{F}, t/4) \geq 2^{H_2(1/4)t}$ （渐进意义下）。

证明. 对任意 $T = \{e_{i_1}, \dots, e_{i_{t/4}}\} \subseteq Y$ ($|T| = t/4$)，定义

$$x_T = \frac{2}{\sqrt{t}} \sum_{e \in T} e.$$

验证合法性： $\|x_T\|^2 = (4/t) \cdot (t/4) = 1$ ； x_T 的每个坐标为 0 或 $2/\sqrt{t}$ ，因 t 是 2 的幂， $2/\sqrt{t}$ 是尺寸 $\leq B = \lceil 2 \log t \rceil$ 的有理数，故 $x_T \in X$ 。令 $X_1 = \{x_T \mid T \subseteq Y, |T| = t/4\}$ 。

考察任意一个恰含 $t/4$ 个 1 的长度- t 比特串，设其 1 位于 $i_1, \dots, i_{t/4}$ ，取 $T = \{e_{i_1}, \dots, e_{i_{t/4}}\}$ 。则对 $e \in T$ ： $\langle x_T, e \rangle = \langle \frac{2}{\sqrt{t}} \sum_{e' \in T} e', e \rangle = \frac{2}{\sqrt{t}}$ ，故 $f_{x_T}(e) = 1$ ；对 $e \notin T$ ： x_T 与 e 正交， $\langle x_T, e \rangle = 0$ ，故 $f_{x_T}(e) = 0$ 。于是每一个重量为 $t/4$ 的比特串都作为某个 f_{x_T} 在 Y 上的真值表出现。这类比特串共有 $\binom{t}{t/4} \approx 2^{H_2(1/4)t}$ 个（由 Stirling 公式），故 $\text{SC}(\mathcal{F}, t/4) \geq 2^{H_2(1/4)t}$ 。□

推论 1 (论文 Corollary 7) 对一切常数 $\delta < 1/4$, $R^\delta(f) = \Omega(t)$ 。

证明. 由于 $|Y| = t$, 对任何 $X_1 \subseteq X$ 都有 $\text{VCD}(f_{X_1}) \leq t$, 因此可在论文 Theorem 4 中取 $\ell = t$: 存在分布 μ 使得

$$D^{\mu, \delta}(f) \geq \frac{\log \text{SC}(f_{X_1}, t) - t H_2(\delta)}{2} \approx \frac{t(H_2(1/4) - H_2(\delta))}{2} = \Omega(t),$$

其中用到 $\text{SC}(f_{X_1}, t) \geq \text{SC}(\mathcal{F}, t/4) \geq 2^{H_2(1/4)t}$ (重量- $t/4$ 串是全真值表的一部分), 以及 $\delta < 1/4$ 时 $H_2(\delta) < H_2(1/4)$ 使括号内为正常数。再由 Yao 极小极大原则, $R^\delta(f) \geq D^{\mu, \delta}(f) = \Omega(t)$ 。□

注 4 这是全文最技术性的一步, 但核心想法很朴素: x_T 是“指示向量的归一化”, 内积判定恰好读出基向量是否属于 T , 于是 $\Pi_{l_2}(t)$ 的函数族包含了所有重量- $t/4$ 的指示函数——其丰富程度 ($\approx 2^{0.811t}$ 种模式) 迫使 Alice 必须传送 $\Omega(t)$ 位。注意与 ε -set disjointness 的对比: 那里的函数族贫瘠到采样协议就能应付, 而这里的函数族丰富到通信复杂度达到输入尺寸的量级, 这正是新下界能突破 $1/\varepsilon$ 的根本原因。

5.4 $l_2 \rightarrow l_1$ 低畸变嵌入

定义 4 (低畸变嵌入) 映射 $\phi: l_r^t \rightarrow l_s^d$ 称为 $(1+\gamma)$ -畸变嵌入, 若对任意 $p, q \in l_r^t$:

$$\frac{1}{1+\gamma} \|p - q\|_r \leq \|\phi(p) - \phi(q)\|_s \leq \|p - q\|_r.$$

定理 5 (Figiel–Lindenstrauss–Milman [10]; 论文 Theorem 5) 对任意 $\gamma > 0$, 存在 $(1+\gamma)$ -畸变嵌入 $\phi: l_2^t \rightarrow l_1^d$, 其中 $d = O(t \log(1/\gamma)/\gamma^2)$ 。Indyk [11] 基于 p -稳定分布给出了此类嵌入的显式随机化构造。

注 5 (为什么约化需要它) $\Pi_{l_2}(t)$ 的间隙存在于 l_2 距离中, 而 F_0 是汉明重量 (本质是 l_1 /计数量)。从 l_2 到比特串没有保距的直接通道, 但 l_1 有: 把坐标放大为整数后做一元编码, l_1 距离恰好变成汉明距离 (见第 5.5 节)。嵌入 ϕ 就是中间的桥。由于 ϕ 是确定性的且 Alice 与 Bob 都知道, 双方可以各自在本地计算 $\phi(x)$ 、 $\phi(y)$, 不消耗任何通信。畸变参数 γ 最终取 $\Theta(\varepsilon)$: 要足够小以使 $(1+\gamma)$ 的伸缩不淹没 $1/\sqrt{t} = \varepsilon$ 的间隙, 但 γ 越小目标维度 d 越大, 直接决定最终全集大小 m ——这就是参数范围 $m^{-1/9}$ 的来源 (第 5.6 节)。

设 $\gamma = \gamma(t)$ 待定。取定理中的嵌入 $\phi: l_2^t \rightarrow l_1^d$ 。对 $(x, y) \in \Pi_{l_2}(t)$, Alice 计算 $\phi(x)$ 、Bob 计算 $\phi(y)$ 。由畸变性质 (取 $q = 0$ 得范数关系, 取一般 p, q 得距离关系):

$$\frac{1}{1+\gamma} \leq |\phi(x)|, |\phi(y)| \leq 1, \quad (1)$$

$$\frac{\|y - x\|}{1+\gamma} \leq |\phi(y) - \phi(x)| \leq \|y - x\|. \quad (2)$$

5.5 从 $\Pi_{l_2}(t)$ 到 F_0 的约化

约化分三步: 有理近似 $\rightarrow$ 通分放大为整数 $\rightarrow$ 一元编码为比特串, 最后把比特串当作流的特征向量。

第一步：有理近似。 取待定参数 $z = z(t) \in \mathbb{N}$ 。对实数 r ，记 $\{r\}$ 为其小数部分；存在唯一整数 $s \in [0, z)$ 使 $0 \leq \{r\} - s/z \leq 1/z$ ，定义 $\psi(r) = (r - \{r\}) + s/z$ 。对向量逐坐标作用 ψ 。每个坐标改动至多 $1/z$ ， d 个坐标的 l_1 范数总误差至多 d/z ：

$$|\phi(x)| - \frac{d}{z} \leq |\psi(\phi(x))| \leq |\phi(x)| + \frac{d}{z}, \quad (3)$$

$$|\phi(y)| - \frac{d}{z} \leq |\psi(\phi(y))| \leq |\phi(y)| + \frac{d}{z}, \quad (4)$$

$$|\phi(y) - \phi(x)| - \frac{d}{z} \leq |\psi(\phi(y)) - \psi(\phi(x))| \leq |\phi(y) - \phi(x)| + \frac{d}{z}. \quad (5,6)$$

第二步：通分放大为整数。 将每个坐标乘以公分母 z ：记 $s(v) = (zv_1, \dots, zv_d)$ ，则 $s(\psi(\phi(x)))$ 、 $s(\psi(\phi(y)))$ 的所有坐标都是整数，范数同步放大 z 倍。由 (1)、(3) 知 $|\psi(\phi(x))| \leq 1 + d/z \leq 2$ (将保证 $d = o(z)$)，故每个整数坐标的绝对值 $\leq 2z$ 。

第三步：一元编码为比特串。 对整数 $i \in [-2z, 2z]$ ，定义其一元编码为长 $4z$ 的比特串 $u(i) = 1^{i+2z} 0^{2z-i}$ (前 $2z+i$ 位为 1)。对向量逐坐标编码并拼接： $x' = u(s(\psi(\phi(x))))$ ， $y' = u(s(\psi(\phi(y))))$ ，长度均为 $\Theta(zd)$ (论文记为 $(4z+1)d$)。一元编码的关键性质：

$$|v_1 - v_2| = \Delta(u(v_1), u(v_2)), \quad \text{且} \quad \text{wt}(x') = |s(\psi(\phi(x)))|,$$

即 l_1 距离与汉明距离严格相等， l_1 范数与汉明重量严格相等——放大的 z 倍同时出现在两边。由 (1)(3)(4) 得重量界：

$$z\left(\frac{1}{1+\gamma} - \frac{d}{z}\right) \leq \text{wt}(x'), \text{wt}(y') \leq z\left(1 + \frac{d}{z}\right);$$

由 (2)(5)(6) 得距离界：

$$\frac{z\|y-x\|}{1+\gamma} - d \leq \Delta(x', y') \leq z\|y-x\| + d. \quad (7)$$

第四步：把比特串变成流。 把 x' 、 y' 看作全集 $[m]$ ($m = \Theta(zd)$) 上两条流 $a_{x'}$ 、 $a_{y'}$ 的特征向量，则拼接流 $a_{x'} \circ a_{y'}$ 的特征向量是按位或 $x' \vee y'$ ，故 $F_0(a_{x'} \circ a_{y'}) = \text{wt}(x' \vee y')$ 。

引理 2 (论文 Claim 8) 设 $\beta_1(z) \leq \text{wt}(x'), \text{wt}(y') \leq \beta_2(z)$ ，则

$$\beta_1(z) + \frac{\Delta(x', y')}{2} \leq F_0(a_{x'} \circ a_{y'}) \leq \beta_2(z) + \frac{\Delta(x', y')}{2}.$$

证明. 设 c 为“ y' 为 1 而 x' 为 0”的坐标数。逐位计数得 $\Delta(x', y') = \text{wt}(x') - \text{wt}(y') + 2c$ ，即 $c = \frac{1}{2}(\Delta(x', y') + \text{wt}(y') - \text{wt}(x'))$ 。于是

$$\text{wt}(x' \vee y') = \text{wt}(x') + c = \frac{1}{2}(\Delta(x', y') + \text{wt}(x') + \text{wt}(y')),$$

代入 wt 的上下界即得。 □

两种承诺情形的 F_0 间隙。情形 $f(x, y) = 0$: 此时 $\|x - y\| = \sqrt{2}$ 。由 (7) 的下端与引理 (取 $\beta_1 = z(\frac{1}{1+\gamma} - \frac{d}{z})$):

$$F_0 \geq -\frac{3d}{2} + \frac{z}{1+\gamma} + \frac{z\sqrt{2}}{2+2\gamma} = -\frac{3d}{2} + \frac{z(1+\frac{1}{\sqrt{2}})}{1+\gamma}.$$

情形 $f(x, y) = 1$: 此时 $\|x - y\| < \sqrt{2}(1 - \frac{1}{\sqrt{t}})$ 。由 (7) 的上端与引理 (取 $\beta_2 = z(1 + \frac{d}{z})$):

$$F_0 \leq \frac{3d}{2} + z\left(1 + \frac{1}{\sqrt{2}}\right) - \frac{z}{\sqrt{2t}}.$$

两情形的主项同为 $z(1 + 1/\sqrt{2})$, 而间隙为 $\frac{z}{\sqrt{2t}} = \frac{\varepsilon z}{\sqrt{2}}$ (量级 εz), 恰为主项的 $\Theta(\varepsilon)$ 相对间隙; 扰动项是 $\pm 3d/2$ 与 $(1 + \gamma)$ 因子。取 $\varepsilon' = c\varepsilon$ ($c = \frac{1}{3(\sqrt{2}+1)}$ 为小常数), 一个 (ε', δ) -近似 F_0 的算法能区分两情形, 当且仅当

$$(1 + \varepsilon')\left(\frac{3d}{2} + z\left(1 + \frac{1}{\sqrt{2}}\right) - \frac{\varepsilon z}{\sqrt{2}}\right) < (1 - \varepsilon')\left(-\frac{3d}{2} + \frac{z(1 + \frac{1}{\sqrt{2}})}{1 + \gamma}\right). \quad (8)$$

参数求解。若 $d = o(z\varepsilon)$, 含 d 的项被吸收, (8) 在 ε 充分小 (常数) 时等价于

$$(1 + \varepsilon')\left(z\left(1 + \frac{1}{\sqrt{2}}\right) - \frac{\varepsilon z}{\sqrt{2}}\right) < \frac{(1 - \varepsilon')z(1 + \frac{1}{\sqrt{2}})}{1 + \gamma}.$$

取 $c = \frac{1}{3(\sqrt{2}+1)}$, 经代数整理可知 $\gamma = \Theta(\varepsilon)$ 即可使不等式成立。回代各参数:

$$\gamma = \Theta(\varepsilon) \Rightarrow d = O\left(\frac{t \log(1/\gamma)}{\gamma^2}\right) = O\left(\frac{1}{\varepsilon^4} \log \frac{1}{\varepsilon}\right) \Rightarrow z = \omega\left(\frac{1}{\varepsilon^5} \log \frac{1}{\varepsilon}\right) \Rightarrow m = \Theta(zd) = \omega\left(\frac{1}{\varepsilon^9} \log \frac{1}{\varepsilon}\right).$$

于是在全集大小 $m = \Theta(\varepsilon^{-9} \log(1/\varepsilon))$ 上, $(\Theta(\varepsilon), \delta)$ 近似 F_0 的算法可以 δ 误差判定 $\Pi_{l_2}(t)$, 由约化其空间必为 $\Omega(t) = \Omega(1/\varepsilon^2)$ 。

注 6 (约化的正确性要点) 整条链上信息只经历三次“损耗”: 嵌入畸变 $(1+\gamma)$ 、有理近似误差 d/z 、 F_0 估计误差 ε' 。三者都被控制在间隙 εz 之下 (分别为 $\gamma = \Theta(\varepsilon)$ 、 $d = o(z\varepsilon)$ 、 $\varepsilon' = \varepsilon/3(\sqrt{2}+1)$), 因此两种承诺情形在估计值上仍然可分。Alice 发送的是 F_0 算法处理 $a_{x'}$ 后的内部状态, Bob 续跑 $a_{y'}$ 后读出答案——通信量恰为算法空间, 故空间 $\geq R^\delta(f) = \Omega(t)$ 。

5.6 主定理的整合与参数范围

定理 6 (主定理 (论文摘要与第 4 节)) 设 $\delta < 1/4$ 为常数, $k > 0$ 为任意常数。任何在大小为 m 的全集上单趟 (ε, δ) -近似 F_0 的数据流算法, 当

$$\varepsilon = \Omega(m^{-1/(9+k)})$$

时必须使用 $\Omega(1/\varepsilon^2)$ 位空间; 对所有更小的 ε , 空间下界为 $\Omega(m^{2/9})$ 量级。

证明链汇总. (1) 固定 ε , 设 $t = \Theta(1/\varepsilon^2)$ 。由论文 Corollary 7, $\Pi_{l_2}(t)$ 的判定需要 $R^\delta(f) = \Omega(t)$ 的单向通信。(2) 由第 5.5 节的约化, 一个空间为 S 的单趟 $(\Theta(\varepsilon), \delta)$ -近似 F_0 算法给出 $\Pi_{l_2}(t)$ 的 S 位单向协议: Alice 将 x 经“嵌入 $\rightarrow$ 有理近似 $\rightarrow$ 放大 $\rightarrow$ 一元编码”变为流 $a_{x'}$, 运行 F_0 算法并发

送其状态; Bob 对 y 做同样变换得到 $a_{y'}$, 续跑算法并以输出是否超过阈值 $\approx z(1+1/\sqrt{2}) - \frac{1}{2} \cdot \frac{\varepsilon z}{\sqrt{2}}$ 判定 $f(x, y)$ 。两种情形的 F_0 间隙为主项的 $\Theta(\varepsilon)$, 而估计误差为 $\Theta(\varepsilon) < \varepsilon/\sqrt{2}$ (相对主项), 故判定误差 $\leq \delta$ 。(3) 因此 $S = \Omega(t) = \Omega(1/\varepsilon^2)$ 。约化产生的全集大小为 $m = \Theta(\varepsilon^{-9} \log(1/\varepsilon))$, 反解得 $\varepsilon = \Theta((\log m/m)^{1/9})$, 即对任意 $k > 0$, 当 $\varepsilon = \Omega(m^{-1/(9+k)})$ 时下界成立。(4) 对更小的 ε , 取 $\varepsilon_0 = \Theta(m^{-1/9})$ 应用上述构造 (此时约化在同样大小的全集上给出 $\Omega(1/\varepsilon_0^2) = \Omega(m^{2/9})$ 的下界; 对 $\varepsilon < \varepsilon_0$ 的 (ε, δ) -近似同样是 (ε_0, δ) -近似), 即得对所有更小 ε 的 $\Omega(m^{2/9})$ 空间下界。□

注 7 (参数范围与 tightness) 范围限制 $\varepsilon = \Omega(m^{-1/(9+k)})$ 完全来自嵌入的维度膨胀: 确定性嵌入 $d = O(t \log(1/\gamma)/\gamma^2)$ 带来 ε^{-4} , 有理近似的精度要求 $d = o(z\varepsilon)$ 再贡献 ε^{-5} , 合计 $m \approx \varepsilon^{-9}$ 。论文在第 4 节指出两条松动途径: 改用**随机化**嵌入可将 d 降至 $O(\log t/\gamma^2)$; 而 Woodruff [13] 随后直接在 Hamming 空间构造向量集, 把 $1/\varepsilon$ 的上界推进到最优的 $m^{1/2}$ 。就 tightness 而言: 本文下界 $\Omega(1/\varepsilon^2)$ 与当时最优上界 $O((1/\varepsilon^2 \log \log m + \log m \log(1/\varepsilon)) \log(1/\delta))$ [4] 相比, 小 ε 时相差 $\log \log m$ 、大 ε 时相差 $\log(1/\varepsilon)$ ——关于 ε 的依赖已被完全钉死, 剩余的只是 m 与 δ 方向上的低阶因子 (分别由 [20] 与 [21, 22] 在后续工作中消除)。

6 正确性与优越性分析

6.1 证明正确性的检验

6.2 紧性分析: 下界与上界的匹配程度

6.3 遗留问题及其后续解决

7 评价与讨论

本节给出本组对论文的独立评价: 第 7.1 节讨论其非凡之处, 第 7.2 节提出局限与批评, 第 7.3 节分析其对后续研究的影响。

7.1 论文的非凡之处

1. 问对了问题, 并且答得干净利落。 2002 年前后, F_0 估计的上界停滞在 $\tilde{O}(1/\varepsilon^2)$, 下界停滞在 $\Omega(1/\varepsilon)$, “二次方鸿沟”是整个数据流社区公开的尴尬。本文没有在上界侧继续堆砌技巧, 而是直接回答“ $1/\varepsilon^2$ 是不是问题固有的”这一根本问题, 并给出肯定答案。事后看, 这个答案一次性地终结了算法设计上“继续优化 $1/\varepsilon$ 依赖”的所有幻想——好的下界和好的算法一样能推动领域前进, 本文是这一点的教科书式例证。

2. 方法论上的真正创新: 给数据流下界装上了“信息论 + 几何”的引擎。 此前流式下界的约化源都是组合式通信问题 (EQ、set disjointness), 它们的通信复杂度自带容易达到的协议上界, 天花板分别是 $\log m$ 和 $1/\varepsilon$ 。本文的关键洞察是: 要突破天花板, 必须换一个“只有 F_0 算法的全部能力才能解”的 *promise* 问题。欧氏空间中的内积判定 $\Pi_{l_2}(t)$ 恰好满足这一点——它的函数族包含全部重量- $t/4$ 的指示函数, 丰富到任何协议 (包括采样协议) 都必须传 $\Omega(t)$ 位。为把这种几何问题的复杂度“搬运”到汉明空间, 论文串联起 VC 维/shatter coefficient 的信息论工具与 $l_2 \rightarrow l_1$ 低畸变嵌入这两套此前很少在流式下界中同框出现的 machinery, 开创了“几何 promise 问题 $\rightarrow$ 嵌入 $\rightarrow$ 汉明空间 $\rightarrow$ 流”的证明范式。这条流水线此后被反复复用, 成为数据

流下界证明的标准工艺之一。

3. 一个副产品比主定理还要长寿：Gap-Hamming 问题。 本文正式提出的 Gap-Hamming-Distance 问题（判定两比特串汉明距离 $\geq n/2 + \sqrt{n}$ 还是 $\leq n/2 - \sqrt{n}$ ）在随后十年成为理论计算机科学中最高产的通信问题之一：它的多轮下界 [18]、最优下界 [19] 牵动了 round elimination、高斯空间相关性、信息复杂度等多个方向的工具发展，其影响早已溢出 F_0 本身，渗透到频率矩、熵估计、图流等一大批问题的下界证明中。一篇 6 页的会议论文同时贡献了一个紧下界和一个“下界制造机”，这在文献中并不多见。

4. 工具皆为成熟成品，组合方式却出人意料。 Yao 原则（1977）、VC 维（1971）、KNR 定理（1999）、FLM 嵌入（1977）、一元编码——链条上没有任何一个零件是新的，但整台机器是新的。这体现了作者对两个领域（通信复杂性与度量嵌入）工具箱的同时精通，也使得证明在技术上异常扎实：每一步都可以引用现成的强定理，审稿时没有薄弱环节。对我们学习者而言，这是“创新可以来自跨界组合而非单点突破”的极佳示范。

7.2 局限与批评

1. 参数范围不够紧致，留下了 $m^{-1/9}$ 与 $m^{-1/2}$ 之间的 gap。 本文下界仅在 $\varepsilon = \Omega(m^{-1/(9+k)})$ 时给出 $\Omega(1/\varepsilon^2)$ ；对更小（更高精度要求）的 ε ，只剩 $\Omega(m^{2/9})$ 的平庸下界，与上界 $\tilde{O}(1/\varepsilon^2)$ 相去甚远。根源是技术性的：确定性嵌入带来 $d = O(\varepsilon^{-4} \log(1/\varepsilon))$ 的维度膨胀，有理近似的精度要求再放大出 ε^{-5} 。作者自己在结论中也承认可用随机化嵌入松动该界，而最终由 Woodruff [13] 直接构造解决——这说明本文的 $1/9$ 指数并非问题的本质，而是约化路线的“过路费”。换言之，主定理的结论是紧的，但其证明并非最经济的。

2. 模型覆盖面容。 下界只针对单趟、纯插入（insertion-only）流：不覆盖多趟扫描（尽管后来的 GHD 最优下界 [19] 顺带解决了这一点）、不允许元素删除（turnstile 模型）、不涉及滑动窗口；同时只约束空间，对更新时间、哈希函数的随机性代价（实际实现中“真随机哈希”并不存在）均不置一词。此外 δ 被固定为常数，亚常数误差概率下 $\log(1/\delta)$ 因子是否必要，留给了 Jayram-Woodruff [21]。这些留白今天看都已被后续工作填补，但读者需意识到本文结论的适用边界。

3. 行文密度过高，存在若干伤读者的小瑕疵。 全文仅 6 页，大量代数推导被压缩为“after some algebra”；常数 c 、 ε_0 、 z 的选取只给结论不给动机。更令人困扰的是几处不一致：引言中 $\Pi_{l_2}(t)$ 的内积间隙写作 $1/\sqrt{t}$ ，正文定义与推导却用 $2/\sqrt{t}$ ；一元编码长度按定义为 $4z$ ，文中却记比特串长为 $(4z+1)d$ 。这些不影响结论的正确性，但显著增加了独立复现的时间成本——本组在第 5 节的整理中不得不逐一核对原文两处的版本。

4. 结构性直觉着墨不足。 为什么“内积判定”天然具有 $\Omega(1/\varepsilon^2)$ 的复杂度？为什么嵌入必须绕道 l_1 ？论文把这些问题留给读者自行体会，证明读起来像一连串精巧但偶然的代数巧合。直到后来 Gap-Hamming 视角成熟后，“ $1/\varepsilon^2$ 来自中心极限定理尺度的涨落（ $\sqrt{n}$ 级别的汉明距离间隙）”这一清晰图景才被社区普遍接受。如果论文能给出这一高层叙事，其可读性和影响力还会更进一步。

7.3 对后续研究的影响

下界侧: Gap-Hamming 谱系与“全参数最优”的收尾。 本文遗留的两个 gap—— ε 适用范围与证明的经济性——很快被填平: Woodruff [13] 直接在 Hamming 空间构造, 把 $\Omega(1/\varepsilon^2)$ 推进到最优范围 $1/\varepsilon \leq m^{1/2}$; Jayram et al. [17]、Brody–Chakrabarti [18]、Chakrabarti–Regev [19] 沿本文提出的 Gap-Hamming 问题逐级推进, 最终以任意轮数的 $\Omega(n)$ 最优通信下界收尾, 使 F_0 的 $\Omega(1/\varepsilon^2)$ 下界对全参数范围乃至多趟扫描都成立。Jayram–Woodruff [21] 进一步把 $\Omega(\varepsilon^{-2} \log(1/\delta))$ 纳入下界, 封闭了 δ 维度。可以说, 本文之后 F_0 下界研究的每一步都是在“修缮”而非“推翻”本文的结论。

上界侧: 刺激最优算法的诞生。 下界钉死了 $1/\varepsilon^2$ 之后, 算法设计的目标变得明确: 消去 $\log \log m$ 与 $\log(1/\varepsilon)$ 的残余因子。Kane–Nelson–Woodruff [20] 的 $O(1/\varepsilon^2 + \log m)$ 与 Błasiok [22] 的 $O(\varepsilon^{-2} \log(1/\delta) + \log m)$ 先后达标, 且两文的作者都明确以本文下界为对标。上下界在 2018 年于全部参数维度闭合, F_0 估计成为数据流模型中第一个复杂度被完全刻画的基本问题——这个“完结篇”的第一章是本文写的。

范式侧: 通信复杂性驱动流式下界方法论。 本文巩固并升级了 AMS 开创的“流算法空间 $\geq$ 单向通信复杂度”范式: 此后证明流式下界的标准动作变成“设计/借用合适的 promise 通信问题 $\rightarrow$ 信息论工具下界 $\rightarrow$ 嵌入或编码约化到目标问题”。这套方法论外溢到分布式函数监控、消息传递模型 (如 Woodruff–Zhang 关于分布式 F_0 的最优下界)、图流、乃至近年对抗鲁棒流 (adversarially robust streaming) 的分离结果中, 本文的约化技巧始终是这些工作的技术底色。

实践侧: 为工程界的对数级空间正名。 HyperLogLog [16] 等工业标准算法用 $\log \log m$ 级寄存器换取常数相对误差; 本文及其后续工作从反面证明了: 要把相对误差压到 ε , $\Theta(1/\varepsilon^2)$ 的空间代价一分都不能少。理论下界与工程上界的合流, 让“基数估计该花多少内存”第一次有了精确的答案, 也为后续 Pettie–Wang 等人关于基数估计信息论极限 (Fisher 信息视角) 的更精细研究提供了基准。

7.4 本组的理解过程与心得 (可选)

8 总结

参考文献

- [1] P. Indyk and D. P. Woodruff. Tight lower bounds for the distinct elements problem. In *Proc. 44th IEEE Symposium on Foundations of Computer Science (FOCS)*, pages 283–288, 2003.
- [2] P. Flajolet and G. N. Martin. Probabilistic counting algorithms for data base applications. *Journal of Computer and System Sciences*, 31(2):182–209, 1985.
- [3] N. Alon, Y. Matias, and M. Szegedy. The space complexity of approximating the frequency moments. In *Proc. 28th ACM STOC*, pages 20–29, 1996; journal version: *Journal of Computer and System Sciences*, 58(1):137–147, 1999.

- [4] Z. Bar-Yossef, T. S. Jayram, R. Kumar, D. Sivakumar, and L. Trevisan. Counting distinct elements in a data stream. In *Proc. 6th International Workshop on Randomization and Approximation Techniques (RANDOM)*, LNCS 2483, pages 1–10, 2002.
- [5] Z. Bar-Yossef. *The Complexity of Massive Data Set Computations*. Ph.D. thesis, University of California, Berkeley, 2002.
- [6] A. C.-C. Yao. Probabilistic computations: Toward a unified measure of complexity. In *Proc. 18th IEEE FOCS*, pages 222–227, 1977.
- [7] V. N. Vapnik and A. Y. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and its Applications*, 16(2):264–280, 1971.
- [8] I. Kremer, N. Nisan, and D. Ron. On randomized one-round communication complexity. *Computational Complexity*, 8(1):21–49, 1999.
- [9] Z. Bar-Yossef, T. S. Jayram, R. Kumar, and D. Sivakumar. An information statistics approach to data stream and communication complexity. In *Proc. 17th IEEE Conference on Computational Complexity (CCC)*, pages 93–102, 2002.
- [10] T. Figiel, J. Lindenstrauss, and V. D. Milman. The dimension of almost spherical sections of convex bodies. *Acta Mathematica*, 139:53–94, 1977.
- [11] P. Indyk. Stable distributions, pseudorandom generators, embeddings and data stream computation. In *Proc. 41st IEEE FOCS*, pages 189–197, 2000; journal version: *Journal of the ACM*, 53(3):307–323, 2006.
- [12] P. Indyk. Algorithmic applications of low-distortion geometric embeddings. In *Proc. 42nd IEEE FOCS* (invited talk), pages 10–33, 2001.
- [13] D. P. Woodruff. Optimal space lower bounds for all frequency moments. In *Proc. 15th ACM-SIAM SODA*, pages 167–175, 2004.
- [14] P. B. Gibbons and S. Tirthapura. Estimating simple functions on the union of data streams. In *Proc. 13th ACM SPAA*, pages 281–291, 2001.
- [15] M. Durand and P. Flajolet. Loglog counting of large cardinalities. In *Proc. 11th European Symposium on Algorithms (ESA)*, LNCS 2832, pages 605–617, 2003.
- [16] P. Flajolet, É. Fusy, O. Gandouet, and F. Meunier. HyperLogLog: The analysis of a near-optimal cardinality estimation algorithm. In *Proc. 18th International Meeting on Probabilistic, Combinatorial and Asymptotic Methods for the Analysis of Algorithms (AofA)*, DMTCS Proceedings, pages 127–146, 2007.
- [17] T. S. Jayram, R. Kumar, and D. Sivakumar. The one-way communication complexity of Hamming distance. *Theory of Computing*, 4(1):129–135, 2008.

- [18] J. Brody and A. Chakrabarti. A multi-round communication lower bound for Gap Hamming and some consequences. In *Proc. 24th IEEE Conference on Computational Complexity (CCC)*, pages 358–368, 2009.
- [19] A. Chakrabarti and O. Regev. An optimal lower bound on the communication complexity of Gap-Hamming-Distance. In *Proc. 43rd ACM STOC*, pages 51–60, 2011; journal version: *SIAM Journal on Computing*, 41(5):1299–1317, 2012.
- [20] D. M. Kane, J. Nelson, and D. P. Woodruff. An optimal algorithm for the distinct elements problem. In *Proc. 29th ACM PODS*, pages 41–52, 2010.
- [21] T. S. Jayram and D. P. Woodruff. Optimal bounds for Johnson–Lindenstrauss transforms and streaming problems with subconstant error. In *Proc. 22nd ACM-SIAM SODA*, pages 1–10, 2011; journal version: *ACM Transactions on Algorithms*, 9(3):26:1–26:17, 2013.
- [22] J. Błasiok. Optimal streaming and tracking distinct elements with high probability. In *Proc. 29th ACM-SIAM SODA*, pages 2432–2448, 2018; journal version: *ACM Transactions on Algorithms*, 16(1):3:1–3:28, 2020.
- [23] D. P. Woodruff. The average-case complexity of counting distinct elements. In *Proc. 12th International Conference on Database Theory (ICDT)*, pages 284–295, 2009.
- [24] S. Chakraborty, N. V. Vinodchandran, and K. S. Meel. Distinct elements in streams: An algorithm for the (text) book. In *Proc. 30th European Symposium on Algorithms (ESA)*, LIPIcs 244, pages 34:1–34:6, 2022.