

论文 Review: Tight Lower Bounds for the Distinct Elements Problem

瞿池伟 张天驰

2026 年 7 月 29 日

摘要

本文是对 Indyk 与 Woodruff 发表于 FOCS 2003 的论文 *Tight Lower Bounds for the Distinct Elements Problem* 的完整 Review。该论文针对数据流模型中的经典问题——不同元素个数 (F_0) 估计——首次证明了单趟随机化 (ϵ, δ) -近似算法的 $\Omega(1/\epsilon^2)$ 空间下界，将此前 $\Omega(1/\epsilon)$ 的最好下界提升至与上界基本匹配的水平，彻底抹平了该问题长期存在的“二次方鸿沟”。其证明开创性地串联起欧氏空间 promise 问题的单向通信复杂度下界（经 VC 维 / shatter coefficient 信息论工具建立）、 $l_2 \rightarrow l_1$ 低畸变度量嵌入与一元编码约化，并孕育了对后世影响深远的 Gap-Hamming-Distance 通信问题。本 Review 形式化介绍了数据流模型与 (ϵ, δ) -近似的定义，沿“上界—下界—工具”三条线索梳理了相关工作，给出主要定理的正式陈述、证明路线图与完整技术细节，对证明的正确性与下界的紧性进行了独立复核与评价，并讨论了该文在参数范围、模型覆盖面方面的局限及其对后续研究（最优算法的诞生、Gap-Hamming 谱系、通信复杂性驱动的流程下界范式）的深远影响。

目录

1	论文概览	3
1.1	论文基本信息	3
1.2	解决的问题	3
1.3	主要结果概述	3
1.4	本 Review 的组织结构	4
2	问题背景与动机	4
2.1	数据流模型	4
2.2	Distinct Elements 问题 (F_0 估计)	5
2.3	应用动机	6
2.4	为什么研究空间下界	6
3	相关工作	7
3.1	上界: F_0 估计算法的发展	9
3.2	本文之前的空间下界	9
3.3	相关的通信复杂性工作	10
3.4	本文发表之后的新进展	10

4	论文的技术贡献	11
4.1	主要定理	11
4.2	证明路线图	12
4.3	技术直觉	13
4.4	与先前下界技术的对比	13
5	技术细节与证明	15
5.1	预备知识：单向通信复杂性与 Yao 极小极大原则	15
5.2	VC 维与 Shatter Coefficients	15
5.3	$\Pi_{l_2}(t)$ 问题的单向通信复杂度下界	16
5.4	$l_2 \rightarrow l_1$ 低畸变嵌入	17
5.5	从 $\Pi_{l_2}(t)$ 到 F_0 的约化	18
5.6	主定理的整合与参数范围	20
6	正确性与优越性分析	20
6.1	证明正确性的检验	20
6.2	紧性分析：下界与上界的匹配程度	21
6.3	遗留问题及其后续解决	21
7	评价与讨论	22
7.1	论文的非凡之处	22
7.2	局限与批评	22
7.3	对后续研究的影响	23
7.4	本组的理解过程与心得（可选）	24
8	总结	24

1 论文概览

1.1 论文基本信息

本论文 [1] 题为 *Tight Lower Bounds for the Distinct Elements Problem*, 作者为 Piotr Indyk 与 David Woodruff, 两人当时均任职于美国麻省理工学院 (MIT) 计算机科学与人工智能实验室 (CSAIL 前身, Theory Group)。论文发表于第 44 届 IEEE 计算机科学基础年会 (44th Annual IEEE Symposium on Foundations of Computer Science, FOCS 2003)。FOCS 与 STOC 并称理论计算机科学领域的两大顶级会议, 在算法与复杂性理论方向具有最高的学术影响力。Indyk 是数据流算法与降维 (locality-sensitive hashing、低畸变嵌入) 方向的知名学者, Woodruff 当时为 MIT 博士研究生, 其后在数据流与线性代数算法方向做出了一系列奠基性工作。两位作者的组合恰好对应了本文技术的两大支柱: 几何嵌入与通信复杂性下界。

1.2 解决的问题

一句话概括: 本文证明了在单趟数据流模型下, (ϵ, δ) -近似不同元素个数 F_0 所需空间的紧下界 $\Omega(1/\epsilon^2)$, 将该问题的下界从已知的 $\Omega(1/\epsilon)$ 提升到与上界基本匹配的水平。

具体而言, 论文研究的是数据流 (streaming) 模型中的经典问题: 给定来自大小为 m 的全集 $[m] = \{0, 1, \dots, m-1\}$ 的一个元素流 $a = a_1, \dots, a_n$ (元素按对抗性顺序到达, 算法只能单趟扫描), 估计流中不同元素的个数 $F_0 = F_0(a)$ 。由于存在 $\Omega(m)$ 的确定性空间下界, 精确计算甚至确定性近似都不可行, 因此研究界转而寻求随机化近似算法: 称算法 $\mathcal{A}$ 是 F_0 的 (ϵ, δ) -近似, 若其输出 $\tilde{F}_0$ 满足 $\Pr[|\tilde{F}_0 - F_0| > \epsilon F_0] < \delta$ 。

在本文之前, 已知的最好算法 (Bar-Yossef 等人, RANDOM 2002) 使用 $O((1/\epsilon)^2 \log \log m + \log m \cdot \log(1/\epsilon)) \log(1/\delta)$ 的空间, 而最好的空间下界只有 $\Omega(1/\epsilon)$ (基于 ϵ -set disjointness 问题的单向通信复杂度) 以及更早的 $\Omega(\log m)$ 。上界中主导项 $1/\epsilon^2$ 与下界 $1/\epsilon$ 之间存在一个二次方的鸿沟, “还能不能做得更好” 这一根本问题悬而未决。本文正是回答了这一问题。

1.3 主要结果概述

本文的主要结果可非正式地陈述如下 (正式定理陈述见第 4 节):

- **空间下界:** 任何单趟 (ϵ, δ) -近似 F_0 的数据流算法 (δ 为常数), 当 $\epsilon = \Omega(m^{-1/(9+k)})$ 时 ($k > 0$ 为任意常数), 必须使用 $\Omega(1/\epsilon^2)$ 位的空间。这把此前该参数范围内的 $\Omega(1/\epsilon)$ 下界提升了整整一个 $1/\epsilon$ 因子。
- **紧性:** 该下界与当时最优上界几乎匹配——对小 ϵ 仅相差 $\log \log m$ 因子, 对大 ϵ 仅相差 $\log(1/\epsilon)$ 因子。换言之, F_0 估计问题的空间复杂度关于 ϵ 的依赖被本文 (在相差低阶因子的意义下) 最终刻画为 $\Theta(1/\epsilon^2)$ 。
- **技术贡献:** 下界通过一条新颖的约化链获得——从欧氏空间中一个布尔 promise 问题 $\Pi_{l_2}(t)$ (Alice 持单位范数向量 x , Bob 持标准基向量 y , 需区分内积 $\langle x, y \rangle = 0$ 与 $\langle x, y \rangle = 1/\sqrt{t}$) 的单向通信复杂度下界 $\Omega(t)$ 出发, 借助 VC 维/shatter coefficient 的信息论工具 (Kremer–Nisan–Ron 定理及其推广) 建立通信下界, 再经由 Indyk 的 $l_2 \rightarrow l_1$ 低畸变嵌入 (stable distributions 方法), 通过有理近似、通分放大与一元编码将嵌入后的向量转化为比特串, 最终把比特串视为流的特征向量 (F_0 恰为其 Hamming 重量) 完成约化。这一“欧氏问题 $\rightarrow$ 嵌入 $\rightarrow$ 汉明空间 $\rightarrow$ 数据流”的路线是本文的方法论创新, 突破了此前基于集合不交

性 (set disjointness) 的约化只能给出 $\Omega(1/\varepsilon)$ 的瓶颈。

值得注意的是, 本文发表后不久, Kane–Nelson–Woodruff (PODS 2010) 给出了空间 $O(1/\varepsilon^2 + \log m)$ 的最优算法, Woodruff (2004) 也直接改进了 Hamming 空间中的下界构造, 最终使 F_0 估计问题的空间复杂度被完全刻画。本文是这条故事线中确立 $1/\varepsilon^2$ 这一正确量级的主角。

1.4 本 Review 的组织结构

本 Review 其余部分组织如下:

- **第 2 节 (问题背景与动机):** 形式化数据流模型与 F_0 的 (ε, δ) -近似定义, 说明确定性算法的 $\Omega(m)$ 下界, 介绍数据库查询优化、网络流量统计与 DoS 攻击检测等应用, 并解释研究空间下界的意义。
- **第 3 节 (相关工作):** 沿三条线索梳理文献—— F_0 估计算法的发展 (Flajolet–Martin、Alon–Matias–Szegedy、Bar-Yossef 等人)、本文之前的空间下界 ($\Omega(\log m)$ 与 $\Omega(1/\varepsilon)$)、通信复杂性与信息论工具的相关工作, 以及本文发表之后的新进展。
- **第 4 节 (论文的技术贡献):** 给出主要定理的正式陈述与参数适用范围, 画出证明路线图, 解释技术直觉, 并与先前 $\Omega(1/\varepsilon)$ 下界技术对比。
- **第 5 节 (技术细节与证明):** 按“定义—引理—证明—备注”的方式完整展开证明链: 单向通信复杂性与 Yao 极小极大原则、VC 维与 shatter coefficients、 $\Pi_{l_2}(t)$ 的 $\Omega(t)$ 通信下界、 $l_2 \rightarrow l_1$ 低畸变嵌入、从 $\Pi_{l_2}(t)$ 到 F_0 的三步约化, 以及主定理的整合。
- **第 6 节 (正确性与优越性分析):** 记录我们对关键步骤的独立复核, 分析下界与上界的匹配程度 (tightness), 讨论遗留 gap 的后续解决。
- **第 7 节 (评价与讨论):** 给出本组对论文创新点、局限性与历史影响的独立评价。
- **第 8 节 (总结):** 浓缩全文, 概括问题、技术、结论与总体评价。

2 问题背景与动机

2.1 数据流模型

数据流 (data stream) 模型是现代理论计算机科学与大数据处理的核心抽象模型之一。在传统计算模型 (如 RAM 模型) 中, 算法可以无代价或低代价地对存储在内存或磁盘中的数据进行多次随机访问。然而, 随着网络通信、传感器网络、金融交易以及大型数据库系统产生的海量数据呈爆发式增长, 数据的规模往往远超单个计算节点的物理内存容量, 甚至难以完整持久化存储。

形式化而言, 设数据流 $a = a_1, a_2, \dots, a_n$ 为一个由 n 个元素组成的序列, 其中每个元素 a_i 均来自大小为 m 的有限全集 (universe) $[m] = \{0, 1, \dots, m-1\}$ 。数据流模型对算法的计算过程设定了如下严格限制:

1. **单趟扫描 (one-pass scanning):** 数据流中的元素按某种对抗性 (adversarial) 或任意顺序依次到达。算法只能从左到右单趟扫描数据, 无法进行回溯, 也无法重新读取已经处理过的历史数据。
2. **次线性空间复杂度 (sublinear space complexity):** 由于数据流长度 n 和全集大小 m 通常极其庞大 (例如 $n, m \geq 10^9$), 算法被禁止完整保存原始流数据 (耗费 $O(n \log m)$ 位)

或维护全集元素的精确频数位图（耗费 $O(m)$ 位）。算法必须在极小的工作内存（通常为 $\text{polylog}(m, n)$ 或关于近似参数的阶数）下动态维护其内部状态（state / sketch）。

3. **实时状态更新（real-time processing）**：算法在每个元素 a_i 到达时，必须以极高的处理速度（通常为 $O(1)$ 或 $O(\log m)$ 时间）完成内部 sketch 的更新，以满足高吞吐量数据接入的需求。

由于输入数据在到达前不可预知且无法存下全貌，算法在流结束时必须仅依靠其占用的微小内存空间输出对目标函数（如频率矩、统计量）的可靠估计。

2.2 Distinct Elements 问题（ F_0 估计）

不同元素个数估计问题（distinct elements problem），在数据库与数据挖掘领域通常被称为**基数估计（cardinality estimation）**问题，是数据流模型中最经典、研究最深入的基本问题之一。

1. **形式化定义与频率矩框架**。给定来自全集 $[m]$ 的数据流 $a = a_1, \dots, a_n$ ，设 f_i 表示元素 $i \in [m]$ 在流 a 中出现的频数（frequency），即：

$$f_i = |\{j \in [1, n] : a_j = i\}|.$$

在 Alon、Matias 与 Szegedy（AMS [3]）提出的**频率矩（frequency moments）**框架中，第 k 阶频率矩定义为：

$$F_k = \sum_{i=1}^m f_i^k \quad (\text{约定 } 0^0 = 1).$$

当 $k=0$ 时， $f_i^0 = 1$ （若 $f_i > 0$ ）或 0 （若 $f_i = 0$ ）。因此， F_0 恰好等于数据流中不同（不重复）元素的总个数：

$$F_0(a) = |\{a_1, a_2, \dots, a_n\}| = |\{i \in [m] : f_i > 0\}|.$$

2. **确定性计算的硬瓶颈**。试图在单趟流中**精确计算** F_0 或给出**确定性近似**在空间效率上是不可行的。AMS [3] 给出了明确的鸽巢原理与信息论下界：任何能够精确判定 F_0 或提供确定性 $(1 \pm \varepsilon)$ -近似的单趟数据流算法，在最坏情况下必须消耗 $\Omega(m)$ 位的空间——这与直接维护一个长度为 m 的 bit-vector 记录每个元素是否出现过相比，在渐近意义上没有任何优势。

3. **随机化 (ε, δ) -近似**。为了打破 $\Omega(m)$ 的确定性空间壁垒，理论研究转向寻求**随机化近似算法**。算法被允许使用硬币投掷（random bits），并在极高的概率保证下输出带有受控相对误差的估计值。

定义 1 ((ε, δ) -近似算法) 设 $\varepsilon > 0$ 为相对误差参数（relative error）， $\delta \in (0, 1/2)$ 为允许的失败概率（failure probability）。称一个随机化数据流算法 $\mathcal{A}$ 是 F_0 的 (ε, δ) -**近似算法**，若对任意给定的输入数据流 a ，算法输出的估计值 $\tilde{F}_0$ 均满足：

$$\Pr [|\tilde{F}_0 - F_0| > \varepsilon F_0] \leq \delta,$$

其中概率来自算法内部使用的随机比特。算法的目标是在固定 ε 与 δ 的前提下，尽量最小化 sketch 所占用的空间位数（bits of space）。

2.3 应用动机

基数估计在计算机科学的多个实际领域中扮演着底层支柱的角色。由于海量数据场景下“精确去重”的代价极为昂贵，使用次线性空间的 (ε, δ) -近似 F_0 算法成为解决工业界诸多痛点问题的必然选择。

1. 数据库查询优化 (database query optimization)。 在关系型数据库管理系统 (RDBMS) 与现代分布式大数据查询引擎 (如 PostgreSQL、Apache Spark、Presto、ClickHouse) 中，查询优化器 (query optimizer) 负责为复杂的 SQL 查询选择代价最小的执行计划。

- **NDV (number of distinct values) 估计：**优化器需要准确估计属性列上的不重复值个数 (即 NDV)。NDV 是评估多表连接选择性 (join selectivity)、决定连接顺序 (join order) 以及选择连接算法 (如 hash join vs. index nested loop join) 的关键参数。
- **避免全量排序与 hash 开销：**在数百 TB 级别的表上计算精确 NDV 需要执行昂贵的全量排序或建立庞大的 hash 表，这在生成查询计划阶段是不可接受的。采用单趟扫描的 F_0 sketch (如 HyperLogLog [16]) 可以在秒级甚至毫秒级内给出高精度的 NDV 估计，使优化器能快速生成最优执行计划。

2. 网络流量监控与 DDoS 攻击检测 (network traffic monitoring & security)。 高速骨干网路由器 (如 IP 路由器、交换机) 在千兆/万兆链路中面临着每秒数千万数据包的线速 (line-rate) 处理压力，其板载高速缓存 (SRAM) 资源极为有限。

- **网络流量统计：**网络运营商需要实时统计穿过特定路由器的独立源/目的 IP 地址数、独立 TCP 连接数，用以进行流量工程 (traffic engineering)、计费以及网络拓扑变化感知。
- **DoS / DDoS 攻击与网络扫描检测：**在拒绝服务攻击 (DDoS) 或蠕虫病毒扩散 (port scan / IP sweep) 发生时，受害主机或攻击源会在短时间内与海量不重复的 IP 地址或端口建立连接，导致特定流上的 F_0 发生暴增。通过在路由器硬件中部署低内存 F_0 估计算法，可以实现对网络异常流量与攻击行为的实时零延迟告警。

3. 大规模数据清洗与文本去重 (data cleaning & deduplication)。 在 Web 搜索引擎爬虫、海量日志分析以及大型语言模型 (LLM) 预训练数据集预处理中，评估数据集的纯度与唯一性是核心步骤。

- **爬虫与文档指纹：**搜索引擎爬虫通过估计已抓取 URL 或网页指纹 (MinHash / SimHash) 的 F_0 ，来动态调整爬取策略与判断库内文档的重复程度。
- **词表与语料库基数分析：**分析海量文本流中不同 token / 词汇 (vocabulary size) 的规模，帮助评估模型的词表覆盖率。

2.4 为什么研究空间下界

在算法设计中，上界 (upper bound) 告诉我们“问题至少可以在此复杂度下被解决”，而下界 (lower bound) 则从根本上揭示了“问题绝不可能在低于该复杂度下被解决”。研究 F_0 估计问题的空间复杂度下界具有重大且深远的理论与工程意义。

1. 破除“二次方鸿沟” (closing the quadratic gap)。 在本文 (Indyk & Woodruff, FOCS 2003 [1]) 发表之前, 关于 F_0 估计的空间复杂度, 理论界存在着巨大的已知上界与下界之间的缺口:

- **已知最优上界:** Bar-Yossef 等人 (RANDOM 2002 [4]) 给出的算法空间为 $O((\frac{1}{\varepsilon^2} \log \log m + \log m \log \frac{1}{\varepsilon}) \log \frac{1}{\delta})$ 位。当 ε 为常数 (如 $\varepsilon = 10\%$) 时, 内存占用的主导项是 $1/\varepsilon^2$ 。
- **已知最好下界:** 来自 AMS [3] 的 $\Omega(\log m)$ 下界 (基于 equality 问题) 以及 Bar-Yossef 博士论文 [5] 基于 ε -set disjointness 导出的 $\Omega(1/\varepsilon)$ 下界。

在上界主导项 $1/\varepsilon^2$ 与下界 $1/\varepsilon$ 之间存在整整一个二次方的鸿沟 (quadratic gap)。例如, 当用户要求将近似误差从 10% 提高到 1% (ε 缩小 10 倍) 时: 上界算法的空间开销会暴增 100 倍 (因为 $1/\varepsilon^2$), 而理论下界仅增长 10 倍 (因为 $1/\varepsilon$)。这就引发了一个数据流社区多年悬而未决的根本性公开问题: $1/\varepsilon^2$ 究竟是已有算法设计技术的缺陷 (即是否存在只需 $O(1/\varepsilon)$ 或 $O(1/\varepsilon^{1.5})$ 空间的更优算法), 还是该问题本身固有的数学瓶颈? 研究空间下界能够直接对该问题给出权威的否定或肯定回答。

2. 指导算法探索的方向与终点。 下界是研究者的“停机信号”。如果证明了 $\Omega(1/\varepsilon^2)$ 是不可逾越的下界, 算法学家就可以终止寻找 $O(1/\varepsilon)$ 空间算法的尝试, 将精力转向其他更有价值的方向:

- 优化 $1/\varepsilon^2$ 项前面的隐式常数因子 (constant factor);
- 消除或降低低阶依赖项 (如将 $\log m$ 优化为 $\log \log m$);
- 针对特定数据分布 (如 Zipf 分布、随机顺序流) 设计特定场景下的算法。

3. 驱动复杂性理论与证明技术的创新。 从证明技术来看, 传统的简单组合通信问题 (如 equality、set disjointness) 由于自身结构过于简单, 其本身的通信复杂度上限就被卡在 $O(1/\varepsilon)$, 无法作为约化源来导出更高的下界。为了突破 $\Omega(1/\varepsilon)$, 必须寻找全新的、能够使用 F_0 算法全部能力的硬问题。论文正是在探索 F_0 空间下界的过程中, 创新性地引入了高维欧氏空间几何判定问题 ($\Pi_{l_2}(t)$)、VC 维 / shatter coefficient 信息论工具以及 $l_2 \rightarrow l_1$ 低畸变度量嵌入 (low-distortion embedding)。这一套证明范式不仅成功证明了 $\Omega(1/\varepsilon^2)$ 的紧下界, 还孕育出了 Gap-Hamming-Distance (GHD) 等一系列对后续数据流理论产生深远影响的工具。

3 相关工作

本节沿三条线索组织文献: 第 3.1 节梳理 F_0 估计算法 (上界) 的发展, 第 3.2 节回顾本文之前的空间下界, 第 3.3 节介绍本文所用的通信复杂性与嵌入工具的来源, 第 3.4 节讨论本文发表之后的新进展。表 1 给出一个时间线总览。

需要说明的是检索渠道: 论文自身引用的文献 ([2, 3, 4, 5, 8, 9, 7, 10, 11, 13] 等) 以其参考文献表为准; 论文未提及的工作——包括 Gibbons–Tirthapura [14]、Durand–Flajolet [15]、HyperLogLog [16]、Gap-Hamming 下界系列 [17, 18, 19]、Kane–Nelson–Woodruff [20]、Jayram–Woodruff [21]、Błasiok [22] 等——由本组通过 DBLP 与 Google Scholar 检索定位, 并以 arXiv 全文及 ACM Digital Library 记录核实其发表年份、会议与主要结论。

表 1 F_0 估计问题的研究时间线（上界、下界与工具三条线索）

年份	文献	类型	主要结果
1985	Flajolet–Martin [2]	上界	首个概率计数算法，寄存器仅 $O(\log m)$ 位
1996/99	Alon–Matias–Szegedy [3]	上界/下界	频率矩框架；确定性 $\Omega(m)$ 、随机化 $\Omega(\log m)$ 下界
2001	Gibbons–Tirthapura [14]	上界	并流上的 F_0 估计， $\tilde{O}(1/\varepsilon^2)$ 空间
2002	Bar-Yossef et al. [4]	上界	本文之前最优： $O((1/\varepsilon^2 \log \log m + \log m \log \frac{1}{\varepsilon}) \log \frac{1}{\delta})$
2002	Bar-Yossef [5]	下界	经 ε -set disjointness 得 $\Omega(1/\varepsilon)$
1977	Yao [6]	工具	极小极大原则：随机下界 $\Leftarrow$ 分布下确定性下界
1999	Kremer–Nisan–Ron [8]	工具	单向随机通信复杂度 $\geq$ VC 维（相差熵因子）
2002	Bar-Yossef et al. [9]	工具	shatter coefficient 推广，信息论方法
1977	Figiel et al. [10]	工具	$l_2 \rightarrow l_1$ 低畸变嵌入的存在性
2000	Indyk [11]	工具	stable distributions 草图， l_p 范数流计算
2003	Indyk–Woodruff（本文）	下界	$\varepsilon = \Omega(m^{-1/(9+k)})$ 时 $\Omega(1/\varepsilon^2)$
2003	Durand–Flajolet [15]	上界	LogLog 计数，实用化路线的起点
2004	Woodruff [13]	下界	直接在 Hamming 空间构造， $\Omega(1/\varepsilon^2)$ 适用全参数范围
2007	Flajolet et al. [16]	上界	HyperLogLog，工业界标准基数估计算法
2008	Jayram et al. [17]	下界	单向 Hamming 距离通信复杂度 $\Omega(n)$
2009	Brody–Chakrabarti [18]	下界	Gap-Hamming 多轮通信下界
2010	Kane–Nelson–Woodruff [20]	上界	最优算法： $O(1/\varepsilon^2 + \log m)$ （ δ 为常数）
2011	Chakrabarti–Regev [19]	下界	Gap-Hamming 最优 $\Omega(n)$ 随机通信下界（轮数不限）
2011/13	Jayram–Woodruff [21]	下界	$\Omega(\varepsilon^{-2} \log(1/\delta))$ ，刻画 δ 依赖
2018	Błasiok [22]	上界	$O(\varepsilon^{-2} \log(1/\delta) + \log m)$ ，三参数均最优

3.1 上界： F_0 估计算法的发展

F_0 估计（数据库界常称基数估计，cardinality estimation）是数据流模型中研究历史最悠久的问题之一。Flajolet 与 Martin [2]（会议版 1983，期刊版 1985）提出了首个概率计数算法：将每个流元素哈希为均匀随机串，用位图记录哈希值二进制表示中最低位 1 的位置分布；由于随机串中低位连续 0 的长度服从几何分布，最大观测值隐含了不同元素个数的量级信息。该算法每个寄存器只需 $O(\log m)$ 位，多开 R 个寄存器可将相对误差压到约 $1/\sqrt{R}$ ，开创了“用对数级空间换取近似精度”的范式。

Alon、Matias 与 Szegedy [3]（STOC 1996，期刊版 JCSS 1999）系统建立了频率矩（frequency moments） F_k 的流式估计框架。对 F_0 ，他们给出基于随机哈希的 $\text{poly}(1/\varepsilon, \log m)$ 空间算法，同时证明了确定性计算或确定性 $(1 \pm \varepsilon)$ 近似 F_0 需要 $\Omega(m)$ 空间，从而从根本上确立了随机化近似的必要性；此外他们通过将相等性判定问题 EQ 的单向通信复杂度（ $\Theta(\log m)$ ）约化到 F_0 ，得到随机化算法的 $\Omega(\log m)$ 空间下界。这篇论文获 2005 年 Gödel 奖，是数据流算法领域的奠基之作。

此后算法沿两个方向改进。Gibbons 与 Tirthapura [14]（SPAA 2001）基于 distinct sampling 思想，估计多条流之并上的 F_0 等简单函数，空间为 $\tilde{O}(1/\varepsilon^2 \cdot \log m)$ 量级。本文发表之前的最优结果属于 Bar-Yossef、Jayram、Kumar、Sivakumar 与 Trevisan [4]（RANDOM 2002），其算法空间为

$$O\left(\left(\frac{1}{\varepsilon^2} \log \log m + \log m \cdot \log \frac{1}{\varepsilon}\right) \log \frac{1}{\delta}\right),$$

当 δ 为常数时主导项是 $1/\varepsilon^2$ 。正是这个 $1/\varepsilon^2$ 项引出了本文的核心问题：这究竟是算法设计的巧合，还是问题固有的复杂度？

3.2 本文之前的空间下界

与繁荣的上界工作相比，本文之前的下界相当薄弱，只有两条：

$\Omega(\log m)$ 下界（AMS [3]）。思路是将两人单向通信复杂性的相等性问题 EQ（Alice 与 Bob 各持一个 m 位串，判定是否相等，随机化单向通信复杂度为 $\Theta(\log m)$ ）约化为 F_0 计算：Alice 用自己的串作为流的特征向量喂入 F_0 算法，把算法内部状态传给 Bob，Bob 继续喂入自己的串；拼接流的 F_0 值即可判定两串是否相等。因此 F_0 算法的空间至少为 $\Omega(\log m)$ 。这个约化建立了“流算法空间 $\geq$ 通信复杂度”的基本范式，本文与后续所有下界工作都沿用这一范式，只是更换了更精细的通信问题。

$\Omega(1/\varepsilon)$ 下界（Bar-Yossef 博士论文 [5]）。为了得到依赖 ε 的下界，Bar-Yossef 使用 ε -set disjointness 问题：Alice 持有 $x \subseteq [m]$ ， $|x| = m/2$ ；Bob 持有 $y \subseteq [m]$ ， $|y| = \varepsilon m$ ；并承诺要么 $y \subseteq x$ ，要么 $y \cap x = \emptyset$ 。两种情形下拼接流的 F_0 分别为 $m/2$ 与 $m/2 + \varepsilon m$ ，相差恰为相对误差 ε 可分辨的间隙，故 (ε, δ) -近似 F_0 的算法可区分两种情形，继承该通信问题的 $\Omega(1/\varepsilon)$ 单向通信下界。

然而这个约化是“弱”的：它并没有用到 F_0 算法的全部能力。Alice 完全可以不运行 F_0 算法，而是随机采样 $O(1/\varepsilon)$ 个全集元素、检查它们是否属于 x 并把结果发给 Bob——Bob 据此同样能以高概率判定承诺情形。换言之， ε -set disjointness 本身有一个 $O(1/\varepsilon)$ 的直接协议，其通信复杂度上界就是 $O(1/\varepsilon)$ ，用它做约化源永远不可能导出超过 $\Omega(1/\varepsilon)$ 的下界。要突破 $1/\varepsilon$ ，必

须寻找一个“只有 F_0 算法才能高效求解”的 promise 问题——这正是本文选取欧氏空间内积判定问题 $\Pi_{l_2}(t)$ 的动机，详见第 4 节。

3.3 相关的通信复杂性工作

本文证明链所用的工具各有出处，本节简述其来源与在本文中的角色。

Yao 极小极大原则 [6]。 Yao (FOCS 1977) 的经典结果表明：随机算法在最坏输入上的复杂度下界，等于某输入分布下确定性算法在该分布上的复杂度下界（取所有分布中的最大值）。在本文中，它允许作者把“随机化单向协议的通信下界”转化为“某一精心构造的输入分布 μ 下确定性协议的分布通信复杂度 $D^{\mu, \delta}$ 的下界”，从而可以使用信息论工具。

VC 维与单向通信复杂度 (Kremer–Nisan–Ron [8])。 VC 维的概念源于 Vapnik 与 Chervonenkis [7] (1971) 关于经验过程一致收敛的工作，是学习理论的核心概念。Kremer、Nisan 与 Ron [8] (Computational Complexity 1999) 首次建立其与随机化单向通信复杂度的联系：对任意布尔函数 $f: X \times Y \rightarrow \{0, 1\}$ ，存在输入分布 μ 使得 $D^{\mu, \delta}(f) \geq \ell(1 - H_2(\delta))$ ，其中 ℓ 是函数族 f 的 VC 维。即“函数族越丰富 (VC 维越大)，单向通信越贵”。

Shatter coefficient 推广 (Bar-Yossef et al. [9])。 当 VC 维难以直接计算时，Bar-Yossef、Jayram、Kumar 与 Sivakumar [9] (CCC 2002) 的信息论方法给出更灵活的版本：对任意 $\ell \geq \text{VCD}$ ， $D^{\mu, \delta}(f) \geq (\log \text{SC}(f, \ell) - \ell \cdot H_2(\delta))/2$ 。本文对 $\Pi_{l_2}(t)$ 的 VC 维没有好办法直接算，正是靠构造一个大小为 $\Theta(t)$ 、shatter coefficient 接近 $2^{\Theta(t)}$ 的点集应用此定理，才拿到 $\Omega(t)$ 的通信下界（第 5 节详述）。

$l_2 \rightarrow l_1$ 低畸变嵌入 (Figiel et al. [10]; Indyk [11])。 嵌入定理本身来自 Banach 空间几何：Figiel、Lindenstrauss 与 Milman [10] (Acta Mathematica 1977) 证明了对任意 γ ，存在 $(1 + \gamma)$ -畸变嵌入 $\phi: l_2^t \rightarrow l_1^d$ ， $d = O(t \log(1/\gamma)/\gamma^2)$ 。Indyk [11] (FOCS 2000，期刊版 JACM 2006) 基于 stable distributions (p -稳定分布) 给出了这类嵌入的显式随机化构造，并开创了其在 l_p 范数数据流计算中的应用；他在 FOCS 2001 的特邀报告 [12] 系统总结了低畸变嵌入的算法应用。本文把这条嵌入链用作“几何问题 $\rightarrow$ 汉明空间 $\rightarrow$ 数据流”约化中的关键桥梁。

3.4 本文发表之后的新进展

本文发表后，围绕 F_0 的上界、下界与应用三条线都迅速推进，最终在 2018 年前后使该问题的空间复杂度在所有参数维度上被完全刻画。

下界的完善。 Woodruff [13] (SODA 2004，即本文参考文献 [11]) 放弃了“先嵌入到 l_1 再到 Hamming 空间”的间接路线（该路线使维度膨胀多项式因子，导致本文的 ε 适用范围只有 $\Omega(m^{-1/(9+k)})$ ），改为直接在 Hamming 空间用精细的概率方法构造向量集，对所有频率矩得到最优空间下界；对 F_0 而言这把 $\Omega(1/\varepsilon^2)$ 的适用范围从 $\varepsilon = \Omega(m^{-1/(9+k)})$ 大幅拓宽。

本文另一个影响深远的遗产是 Gap-Hamming-Distance (GHD) 通信问题——判定两比特串的汉明距离是 $\geq n/2 + \sqrt{n}$ 还是 $\leq n/2 - \sqrt{n}$ ，由本文正式提出。它迅速成为数据流下界的标准约化源：Jayram、Kumar 与 Sivakumar [17] (Theory of Computing 2008) 证明了其单向版本

(Hamming 距离判定) 的 $\Omega(n)$ 下界; Brody 与 Chakrabarti [18] (CCC 2009) 将其推进到受限多轮协议; Chakrabarti 与 Regev [19] (STOC 2011, 期刊版 SICOMP 2012) 最终证明了任意轮数随机协议的 $\Omega(n)$ 最优下界, 彻底解决了本文留下的猜想。由 GHD 到 F_0 的约化随即给出适用于全部参数范围、且对多趟扫描也成立的 $\Omega(1/\varepsilon^2)$ 空间下界。Jayram 与 Woodruff [21] (SODA 2011, 期刊版 ACM TALG 2013) 进一步把对误差概率 δ 的依赖也纳入下界, 证明 $\Omega(\varepsilon^{-2} \log(1/\delta))$, 说明“ $\log(1/\delta)$ 倍独立重复”这一朴素做法在渐近意义下不可改进。

最优算法的出现。 上界方面, Kane、Nelson 与 Woodruff [20] (PODS 2010) 给出了空间 $O(1/\varepsilon^2 + \log m)$ 的算法 (δ 为常数), 与本文下界精确匹配, 首次证明 F_0 估计的空间复杂度就是 $\Theta(1/\varepsilon^2 + \log m)$ 。Błasiok [22] (SODA 2018, 期刊版 ACM TALG 2020) 把最优性推广到亚常数误差概率: 空间 $O(\varepsilon^{-2} \log(1/\delta) + \log m)$, 对 ε 、 δ 、 m 三个参数同时最优, 且支持 strong tracking (整个流过程中持续输出正确估计)。至此, 由本文确立 $1/\varepsilon^2$ 量级所开启的故事在上界一侧也宣告完结。

实用化与变体。 与应用社区并行的是实用算法的演进: Durand 与 Flajolet [15] (ESA 2003) 的 LogLog 计数与 Flajolet 等人 [16] (AofA 2007) 的 HyperLogLog 把 F_0 估计做到每个寄存器仅 $\log \log m$ 位, 成为 Redis、Presto 等工业系统中的标准组件; 与本文的理论结果对照可以看到, 工程界接受的常数因子与模型差异 (哈希视为随机预言、插入流) 正是理论最优结果允许的空间。此外 Woodruff [23] (ICDT 2009) 证明即使流元素按随机顺序到达 (平均情形), F_0 估计仍需 $\Omega(1/\varepsilon^2)$ 空间, 说明本文的困难性并非来自对抗性顺序的人为假设。2022 年 Chakraborty、Vinodchandran 与 Meel [24] (ESA 2022) 提出的 CVM 算法则以极简形式重新实现了最优空间, 被称为“可以写进教科书”的算法, 可视为这条研究线的教学化终点。

4 论文的技术贡献

4.1 主要定理

论文的核心贡献在于首次给出了单趟数据流模型下估计不同元素个数 (F_0 估计) 关于相对误差参数 ε 的紧空间下界。

定理 1 (F_0 估计的空间下界 [1]) 设 $\delta \in (0, 1/4)$ 为常数, $k > 0$ 为任意给定常数。对于来自大小为 m 的全集 $[m] = \{0, 1, \dots, m-1\}$ 的单趟数据流 $a = a_1, \dots, a_n$, 任何能够以至少 $1 - \delta$ 的成功概率 (ε, δ) -近似不同元素个数 $F_0(a)$ (即输出 $\tilde{F}_0$ 满足 $\Pr[|\tilde{F}_0 - F_0| > \varepsilon F_0] \leq \delta$) 的随机化数据流算法, 当相对误差满足

$$\varepsilon = \Omega(m^{-\frac{1}{9+k}})$$

时, 算法所消耗的空间复杂度必须满足:

$$S = \Omega\left(\frac{1}{\varepsilon^2}\right) \text{ bits.}$$

对所有更小的 ε (即 $\varepsilon = O(m^{-1/9})$), 算法所需的紧空间下界为 $\Omega(m^{2/9})$ 位。

紧性与参数说明。

1. 与最优上界的匹配度。此前 Bar-Yossef 等人 (RANDOM 2002 [4]) 给出的最优上界为 $O((\frac{1}{\varepsilon^2} \log \log m + \log m \cdot \log \frac{1}{\varepsilon}) \log \frac{1}{\delta})$ 。在 δ 为常数的前提下：


- 当 ε 较小时，下界 $\Omega(1/\varepsilon^2)$ 与上界的主导项仅相差低阶因子 $\log \log m$ ；
- 当 ε 较大时，下界与上界仅相差 $\log(1/\varepsilon)$ 因子。

因此，论文将 F_0 近似估计关于误差项 ε 的空间复杂度瓶颈彻底钉死在了 $\Theta(1/\varepsilon^2)$ ，抹平了此前该问题长久存在的“二次方鸿沟” ($\Omega(1/\varepsilon)$ 对 $\tilde{O}(1/\varepsilon^2)$)。

2. 适用参数范围的由来。条件 $\varepsilon = \Omega(m^{-1/(9+k)})$ 反映了从几何 promise 问题约化到汉明空间数据流时，由几何嵌入维度膨胀与坐标有理近似精度所付出的全集尺寸 m 的多项式代价。

4.2 证明路线图

论文的整体证明体系建立在单向通信复杂性与度量空间嵌入 (metric embeddings) 的有机结合之上。整体证明链条可拆解为以下 5 个核心步骤：



证明步骤分述。

1. 定义欧氏空间 promise 问题 $\Pi_{l_2}(t)$ 。设 $t = \Theta(1/\varepsilon^2)$ (不妨设 t 为 2 的幂)。Alice 持有单位范数向量 $x \in [0, 1]^t$ ($\|x\|_2 = 1$)，Bob 持有标准基向量 $y \in E = \{e_1, \dots, e_t\} \subset \mathbb{R}^t$ 。承诺条件：双方被保证内积 $\langle x, y \rangle$ 要么为 0 (此时 $f(x, y) = 0$)，要么为 $\frac{2}{\sqrt{t}}$ (此时 $f(x, y) = 1$)，坐标均为精细控制尺寸的有理数。距离间隙转化：由 $\|y - x\|_2^2 = \|y\|_2^2 + \|x\|_2^2 - 2\langle x, y \rangle = 2 - 2\langle x, y \rangle$ 容易导出：当 $\langle x, y \rangle = 0$ 时 $\|y - x\|_2 = \sqrt{2}$ ；当 $\langle x, y \rangle = \frac{2}{\sqrt{t}}$ 时 $\|y - x\|_2 < \sqrt{2}(1 - \frac{1}{\sqrt{t}}) = \sqrt{2}(1 - \varepsilon)$ 。
2. 建立 $\Pi_{l_2}(t)$ 的单向通信复杂度下界 $\Omega(t)$ 。函数族构造：对每一个大小为 $t/4$ 的基向量子集 $T \subset Y$ ，构造归一化指示向量 $x_T = \frac{2}{\sqrt{t}} \sum_{e \in T} e$ 。其与任意 $e \in Y$ 的内积恰好能区分 $e \in T$ (内积为 $2/\sqrt{t}$) 与 $e \notin T$ (内积为 0)。Shatter coefficient 结合：包含 $t/4$ 个 1 的真值表模式共有 $\binom{t}{t/4} \approx 2^{H_2(1/4)t}$ 种。利用 Bar-Yossef 等人 (2002 [9]) 推广的 KNR 定理 [8]，导出对任意 $\delta < 1/4$ ，确定性分布通信复杂度 $D_{\mu, \delta}(f) = \Omega(t)$ 。Yao 极小极大原则：推出随机化单向通信复杂度 $R_\delta(\Pi_{l_2}(t)) = \Omega(t) = \Omega(1/\varepsilon^2)$ 。
3. 度量嵌入与坐标离散化 ($\ell_2^t \rightarrow \ell_1^d \rightarrow \text{Hamming}$)。 $\ell_2 \rightarrow \ell_1$ 嵌入：应用 Figiel–Lindenstrauss–Milman [10] / Indyk [11] 的 $(1 + \gamma)$ -畸变嵌入 $\phi: \ell_2^t \rightarrow \ell_1^d$ (其中 $d = O(t \log(1/\gamma)/\gamma^2)$ ，取 $\gamma = \Theta(\varepsilon)$)，将 ℓ_2 距离间的 ε 相对间隙保距映射到 ℓ_1 空间。有理近似与通分：取公分母 $z = \omega(\varepsilon^{-5} \log(1/\varepsilon))$ ，将 $\phi(x), \phi(y)$ 的各坐标映射为有理数并放大 z 倍，得到整

数向量 $s(\psi(\phi(x))), s(\psi(\phi(y)))$ 。一元编码 (unary encoding): 将范围在 $[-2z, 2z]$ 内的整数坐标转换为长度为 $4z$ 的一元比特串 $u(i) = 1^{i+2z}0^{2z-i}$ 。因一元编码具备关键性质 $\Delta(u(i_1), u(i_2)) = |i_1 - i_2|$ 且 $\text{wt}(u(i)) = 2z + i$, 两向量经拼接后的长比特串 $x', y' \in \{0, 1\}^m$ 满足: 汉明距离严格对应 ℓ_1 距离, $\Delta(x', y') = |s(\psi(\phi(x))) - s(\psi(\phi(y)))|$; 汉明重量严格对应 ℓ_1 范数, $\text{wt}(x') = |s(\psi(\phi(x)))|$ 。

4. 约化至数据流 F_0 估计。Alice 将 x' 视作数据流 $a_{x'}$ 的特征向量并在本地运行 F_0 算法, 将算法内存状态 (S 位) 发给 Bob; Bob 继续喂入 y' 对应的数据流 $a_{y'}$, 输出拼接流 $a_{x'} \circ a_{y'}$ 的不同元素估计值 $\tilde{F}_0$ 。核心等式: 拼接流的 F_0 即为位或向量 $x' \vee y'$ 的汉明重量:

$$F_0(a_{x'} \circ a_{y'}) = \text{wt}(x' \vee y') = \frac{1}{2}(\Delta(x', y') + \text{wt}(x') + \text{wt}(y')).$$

由于双方控制了 $\text{wt}(x')$ 与 $\text{wt}(y')$ 的波动范围, $\Delta(x', y')$ 在 $\langle x, y \rangle = 0$ 和 $\langle x, y \rangle = 2/\sqrt{t}$ 两种情形下的相对间隙直接传递给 F_0 。

5. 参数代入与结论推演。一个误差为 $c\varepsilon$ 的 F_0 算法能够成功区分 $\Pi_{l_2}(t)$ 的两种承诺情形, 从而给出 $\Pi_{l_2}(t)$ 的一个单向通信协议。通信量即为算法空间 $S \geq R_\delta(\Pi_{l_2}(t)) = \Omega(t) = \Omega(1/\varepsilon^2)$ 。全集大小 $m = (4z + 1)d = \Theta(zd) = \omega(\varepsilon^{-9} \log(1/\varepsilon))$, 导出主定理。

4.3 技术直觉

为什么估计不同元素个数需要 $\Omega(1/\varepsilon^2)$ 的空间? 其背后的深层计算复杂性与概率几何直觉可总结为以下三点:

1. 中心极限定理与统计涨落的 $\sqrt{t}$ 尺度。在概率论与统计学中, 要从随机涨落中分辨出相对幅度为 ε 的信号, 通常需要 $O(1/\varepsilon^2)$ 数量级的观测样本。在汉明空间中, 当两个长度为 m 的比特串汉明重量为 $\Theta(m)$ 时, 随机采样或降维哈希带来的自然标准差涨落为 $O(\sqrt{m})$ 。若要分辨相对大小为 ε 的距离差异, 必须满足 $\varepsilon m \geq \Omega(\sqrt{m})$, 即维度 m 或信息自由度 t 必须达到 $\Omega(1/\varepsilon^2)$ 。
2. 欧氏 promise 问题 $\Pi_{l_2}(t)$ 的信息丰富度。此前下界证明失败的原因在于使用了过于“简单”的组合承诺问题 (如集合不交性 ε -DISJ)。在 ε -DISJ 中, Alice 只需随机采样 $O(1/\varepsilon)$ 个元素发给 Bob 即可高概率解决问题, 因此其通信复杂度本身就被限制在 $O(1/\varepsilon)$ 。本文设计的 $\Pi_{l_2}(t)$ 则完全不同: 通过在 t 维单位球面上构造由 $t/4$ -指示向量生成的向量族 x_T , 其对应的布尔函数族 $\mathcal{F}$ 在 t 个基向量上的 shatter coefficient 达到了 $2^{\Omega(t)}$ 。这意味着 Bob 面对的是一个指数级的真值表空间, 不存在任何轻量级的采样协议能够敷衍过关。Alice 必须向 Bob 传输 $\Omega(t)$ 位的真实信息, Bob 才能准确推断出内积值。
3. 位或操作 (bitwise OR) 与 F_0 的几何代数桥梁。数据流算法中的 F_0 估计本质上是对流特征向量进行按位或操作 ($\vee$) 后的汉明重量。由于代数恒等式 $\text{wt}(x' \vee y') = \frac{1}{2}(\Delta(x', y') + \text{wt}(x') + \text{wt}(y'))$, 只要通过约束编码使输入向量的个体范数 (重量 $\text{wt}(x'), \text{wt}(y')$) 保持高度集中, F_0 估计器的测量能力就被完全且等价地转化为对汉明距离 $\Delta(x', y')$ 的测量能力。正是这一桥梁使得几何空间中的保距嵌入能够无缝对接数据流计算。

4.4 与先前下界技术的对比

为了更清晰地展现本文的技术突破, 表 2 将 Indyk-Woodruff (FOCS 2003) 的下界技术与此前的代表性工作进行了多维度横向对比。

表 2 本文与先前 F_0 空间下界技术的多维度对比

维度 / 特性	AMS 下界 (STOC 1996) [3]	Bar-Yossef 下界 (Thesis 2002) [5]	本文 Indyk–Woodruff (FOCS 2003) [1]
导出的空间下界	$\Omega(\log m)$	$\Omega(1/\varepsilon)$	$\Omega(1/\varepsilon^2)$ (当 $\varepsilon = \Omega(m^{-1/9})$)
约化源问题 (promise problem)	相等性问题 $EQ(x, y)$	ε -集合不交性 ε -DISJ(x, y)	欧氏空间内积判定 $\Pi_{l_2}(t)$
源问题的通信复杂度	$\Theta(\log m)$	$\Theta(1/\varepsilon)$	$\Theta(t) = \Theta(1/\varepsilon^2)$
源问题函数族丰富度	极低 (仅判定是否完全一致)	较低 (存在 $O(1/\varepsilon)$ 随机采样协议)	极高 (shatter coefficient $\geq 2^{\Omega(t)}$)
核心数学与几何工具	朴素单向通信约化	简单集合包含/不交判定	VC 维 / shatter coefficient + $\ell_2 \rightarrow \ell_1$ 低畸变嵌入 + 一元编码
对 F_0 算法能力的检验	仅检验算法状态能否区分“相同/不同”	仅检验算法状态能否区分“包含/不交”	完全逼出并检验了 F_0 算法对微小距离间隙的极限定量分辨能力
瓶颈与历史局限	完全无法给出关于 ε 的依赖	受到 ε -DISJ 本身通信上限 $1/\varepsilon$ 的封顶限制	成功突破 $1/\varepsilon$ 瓶颈, 但受嵌入维度膨胀影响, 适用全集范围为 $m = \Omega(\varepsilon^{-9})$

对比总结。 AMS (1996) 确立了“数据流算法空间 $\geq$ 单向通信复杂度”的基本范式; Bar-Yossef (2002) 尝试引入 ε -DISJ 以建立 ε 依赖, 但由于约化源过于脆弱, 导致下界在 $\Omega(1/\varepsilon)$ 处遭遇瓶颈; 这篇论文则在方法论上彻底革新了约化源的构建方式, 引入了具备指数级 shatter coefficient 的欧氏几何 promise 问题, 并成功搭起了“几何空间 $\rightarrow$ 嵌入 $\rightarrow$ 离散编码 $\rightarrow$ 汉明流”的技术流水线, 最终打破了长达数年的二次方鸿沟, 完全确立了 $1/\varepsilon^2$ 的正确量级。

5 技术细节与证明

本节完整展开论文的证明链。记二元熵函数 $H_2(p) = -p \log_2 p - (1-p) \log_2 (1-p)$; 对向量 v , $|v|$ 表示其 l_1 范数, $\|v\|$ 表示其 l_2 范数; 对比特串 x , $\text{wt}(x)$ 表示其中 1 的个数, $\Delta(x, y)$ 表示 x 与 y 的汉明距离。本节中的定理编号沿用论文原文编号 (论文 Theorem 3–6、Corollary 7、Claim 8), 以便读者对照原文核验。

5.1 预备知识：单向通信复杂性与 Yao 极小极大原则

定义 2 (单向协议与通信复杂度; 论文 Definition 1) 设 $f : X \times Y \rightarrow \{0, 1\}$ 为布尔函数。Alice 持输入 $x \in X$, Bob 持输入 $y \in Y$ 。在**单向 (one-way)** 协议中, Alice 计算某个只依赖 x 的消息 $A(x)$ 发送给 Bob, Bob 根据 $A(x)$ 与 y 输出对 $f(x, y)$ 的猜测。协议 Π 的**通信代价**是所有输入上 Alice 发送的最长消息的期望长度。 f 的 δ -**误差随机化 (单向) 通信复杂度** $R^\delta(f)$ 是在所有输入上满足 $\Pr[\Pi(x, y) \neq f(x, y)] \leq \delta$ 的最优协议的通信代价。对输入分布 μ , f 的 δ -**误差 μ -分布通信复杂度** $D^{\mu, \delta}(f)$ 是在 μ 下误差不超过 δ 的最优确定性协议的通信代价。

定理 2 (Yao 极小极大原则 [6]) 对任意布尔函数 f 、误差 δ 与任意输入分布 μ , $R^\delta(f) \geq D^{\mu, \delta}(f)$ 。

注 1 (为什么这条原则对本文至关重要) 随机化协议可以看作确定性协议分布上的一个随机变量: 若每个确定性协议在某分布 μ 下都要付出高昂通信代价才能取得低误差, 那么随机化协议 (确定性协议的混合) 在 μ 的某个输入上也不可能做得更好。因此, 要证明**随机化单向协议**的下界, 只需**自由地设计一个难处理的输入分布 μ** , 然后分析确定性协议在该分布下的表现——后者可以用信息论工具精确刻画。本文第 5.3 节正是沿此路线: 先构造分布 (通过 shatter coefficient 间接给出), 再推出 $D^{\mu, \delta} = \Omega(t)$ 。

注 2 (从通信下界到流算法空间下界) 这是 AMS [3] 确立的标准范式: 设 $\mathcal{A}$ 是空间为 S 的单趟 (ε, δ) -近似 F_0 算法。Alice 把自己的输入编码为一段流, 在本地运行 $\mathcal{A}$ 后把**算法的全部内部状态** (至多 S 位) 发给 Bob; Bob 把状态载入自己的 $\mathcal{A}$ 副本, 继续处理自己输入对应的流段。若拼接流的 F_0 值能区分通信问题的两种承诺情形, 则 $S \geq R^\delta(f)$ 。整条证明链的最终一环 (第 5.5 节) 就是这个范式的一次精细实例化。

5.2 VC 维与 Shatter Coefficients

定义 3 (Shatter coefficient 与 VC 维; 论文 Definition 2) 设 $\mathcal{F} = \{f : X \rightarrow \{0, 1\}\}$ 是域 X 上的布尔函数族。对子集 $S \subseteq X$, 其 **shatter coefficient** 为 $\text{SC}(\mathcal{F}|_S) = |\{f|_S\}_{f \in \mathcal{F}}|$, 即把 $\mathcal{F}$ 中函数限制到 S 上所能得到的不同比特模式数。第 ℓ 个 shatter coefficient $\text{SC}(\mathcal{F}, \ell)$ 是所有大小为 ℓ 的子集上该数量的最大值。若 $\text{SC}(\mathcal{F}|_S) = 2^{|S|}$, 称 S 被 $\mathcal{F}$ **打散 (shattered)**; $\mathcal{F}$ 的 **VC 维**

$\text{VCD}(\mathcal{F})$ 是能被打散的最大子集的大小。

定理 3 (Kremer–Nisan–Ron [8]; 论文 Theorem 3) 对任意 $f : X \times Y \rightarrow \{0, 1\}$ 与任意 $0 < \delta < 1$, 存在 $X \times Y$ 上的分布 μ 使得

$$D^{\mu, \delta}(f) \geq \ell(1 - H_2(\delta)), \quad \ell = \text{VCD}(f_X),$$

其中 $f_X = \{f_x : Y \rightarrow \{0, 1\} \mid x \in X\}$, $f_x(y) = f(x, y)$ 。

定理 4 (Bar-Yossef et al. [9]; 论文 Theorem 4) 对任意 $f : X \times Y \rightarrow \{0, 1\}$ 、任意 $\ell \geq \text{VCD}(f_X)$ 与任意 $\delta > 0$, 存在分布 μ 使得

$$D^{\mu, \delta}(f) \geq \frac{\log \text{SC}(f_X, \ell) - \ell \cdot H_2(\delta)}{2}.$$

注 3 (工具的角色) 直觉是：单向协议中 Bob 只能依靠 Alice 的消息区分不同的 x ；若函数族 f_X 在某个大小为 ℓ 的 y -集合上能产生 $2^{\Omega(\ell)}$ 种不同的真值模式，那么 Alice 的消息必须编码 $\Omega(\ell)$ 位信息才能让 Bob 以低误差输出正确模式——熵因子 $H_2(\delta)$ 是允许 δ 误差带来的折扣。论文 Theorem 3 要求算出 VC 维，而本文面对的函数族（欧氏内积判定）VC 维难以直接计算；Theorem 4 允许用任意 $\ell \geq \text{VCD}$ 配上 shatter coefficient 的下界，只要构造出“模式足够多”的点集即可，这正是第 5.3 节的打法。

5.3 $\Pi_{l_2}(t)$ 问题的单向通信复杂度下界

固定 ε , 令 $t = t(\varepsilon) = \Theta(1/\varepsilon^2)$ (不妨设 t 为 2 的幂)。

定义 4 ($\Pi_{l_2}(t)$; 论文第 3.1 节) 令 $E = \{e_1, \dots, e_t\}$ 为 $\mathbb{R}^t$ 的标准基。先定义

$$\Pi'_{l_2}(t) = \{(x, y) \in [0, 1]^t \times E \mid \|x\| = 1, \langle x, y \rangle = 0 \text{ 或 } \langle x, y \rangle = 2/\sqrt{t}\}.$$

为使坐标可被有限描述且能赋予概率分布，将有理数 p/q 的**尺寸**定义为 $\lceil \log_2 p \rceil + \lceil \log_2 q \rceil + 1$, 并设 $B = \lceil 2 \log t \rceil$ 。定义

$$\Pi_{l_2}(t) = \{(x, y) \in \Pi'_{l_2}(t) \mid \forall i, x_i, y_i \text{ 为尺寸 } \leq B \text{ 的有理数}\}.$$

令 X, Y 分别为可出现于合法输入对中的 x, y 之集合。对 $(x, y) \in \Pi_{l_2}(t)$, 定义 $f(x, y) = 0$ 若 $\langle x, y \rangle = 0$, $f(x, y) = 1$ 若 $\langle x, y \rangle = 2/\sqrt{t}$ 。函数族为 $\mathcal{F} = f_X = \{f_x : Y \rightarrow \{0, 1\} \mid x \in X\}$ 。

引理 1 (内积间隙 $\Rightarrow$ 距离间隙; 论文第 3.1 节末) 对 $(x, y) \in \Pi_{l_2}(t)$:

$$f(x, y) = 0 \Rightarrow \|y - x\| = \sqrt{2}, \quad f(x, y) = 1 \Rightarrow \|y - x\| < \sqrt{2} \left(1 - \frac{1}{\sqrt{t}}\right).$$

证明. 由 $\|y - x\|^2 = \|y\|^2 + \|x\|^2 - 2\langle x, y \rangle$ 及 $\|x\| = \|y\| = 1$: 当 $f(x, y) = 0$ 时 $\|y - x\|^2 = 2$; 当 $f(x, y) = 1$ 时 $\|y - x\|^2 = 2 - 4/\sqrt{t}$, 于是 $\|y - x\| = \sqrt{2}\sqrt{1 - 2/\sqrt{t}} < \sqrt{2}(1 - 1/\sqrt{t})$, 最后一步用到 $\sqrt{1 - u} < 1 - u/2$ ($0 < u < 1$)。□

这条引理是整条约化的支点：内积的 $2/\sqrt{t}$ 间隙被转化为 l_2 距离的 $(1 - 1/\sqrt{t})$ 相对间隙，而距离（而非内积）才能经嵌入与编码一路传递到 F_0 。

定理 5 (论文 Theorem 6) $\mathcal{F}$ 的第 $t/4$ 个 shatter coefficient 满足 $\text{SC}(\mathcal{F}, t/4) \geq 2^{H_2(1/4)t}$ (渐进意义下)。

证明. 对任意 $T = \{e_{i_1}, \dots, e_{i_{t/4}}\} \subseteq Y$ ($|T| = t/4$), 定义

$$x_T = \frac{2}{\sqrt{t}} \sum_{e \in T} e.$$

验证合法性: $\|x_T\|^2 = (4/t) \cdot (t/4) = 1$; x_T 的每个坐标为 0 或 $2/\sqrt{t}$, 因 t 是 2 的幂, $2/\sqrt{t}$ 是尺寸 $\leq B = \lceil 2 \log t \rceil$ 的有理数, 故 $x_T \in X$ 。令 $X_1 = \{x_T \mid T \subseteq Y, |T| = t/4\}$ 。

考察任意一个恰含 $t/4$ 个 1 的长度- t 比特串, 设其 1 位于 $i_1, \dots, i_{t/4}$, 取 $T = \{e_{i_1}, \dots, e_{i_{t/4}}\}$ 。则对 $e \in T$: $\langle x_T, e \rangle = \langle \frac{2}{\sqrt{t}} \sum_{e' \in T} e', e \rangle = \frac{2}{\sqrt{t}}$, 故 $f_{x_T}(e) = 1$; 对 $e \notin T$: x_T 与 e 正交, $\langle x_T, e \rangle = 0$, 故 $f_{x_T}(e) = 0$ 。于是**每一个**重量为 $t/4$ 的比特串都作为某个 f_{x_T} 在 Y 上的真值表出现。这类比特串共有 $\binom{t}{t/4} \approx 2^{H_2(1/4)t}$ 个 (由 Stirling 公式), 故 $\text{SC}(\mathcal{F}, t/4) \geq 2^{H_2(1/4)t}$ 。□

推论 1 (论文 Corollary 7) 对一切常数 $\delta < 1/4$, $R^\delta(f) = \Omega(t)$ 。

证明. 由于 $|Y| = t$, 对任何 $X_1 \subseteq X$ 都有 $\text{VCD}(f_{X_1}) \leq t$, 因此可在论文 Theorem 4 中取 $\ell = t$: 存在分布 μ 使得

$$D^{\mu, \delta}(f) \geq \frac{\log \text{SC}(f_{X_1}, t) - t H_2(\delta)}{2} \approx \frac{t(H_2(1/4) - H_2(\delta))}{2} = \Omega(t),$$

其中用到 $\text{SC}(f_{X_1}, t) \geq \text{SC}(\mathcal{F}, t/4) \geq 2^{H_2(1/4)t}$ (重量- $t/4$ 串是全真值表的一部分), 以及 $\delta < 1/4$ 时 $H_2(\delta) < H_2(1/4)$ 使括号内为正常数。再由 Yao 极小极大原则, $R^\delta(f) \geq D^{\mu, \delta}(f) = \Omega(t)$ 。□

注 4 这是全文最技术性的一步, 但核心想法很朴素: x_T 是“指示向量的归一化”, 内积判定恰好读出基向量是否属于 T , 于是 $\Pi_{l_2}(t)$ 的函数族**包含了所有重量- $t/4$ 的指示函数**——其丰富程度 ($\approx 2^{0.811t}$ 种模式) 迫使 Alice 必须传送 $\Omega(t)$ 位。注意与 ε -set disjointness 的对比: 那里的函数族贫瘠到采样协议就能应付, 而这里的函数族丰富到通信复杂度达到输入尺寸的量级, 这正是新下界能突破 $1/\varepsilon$ 的根本原因。

5.4 $l_2 \rightarrow l_1$ 低畸变嵌入

定义 5 (低畸变嵌入) 映射 $\phi: l_r^t \rightarrow l_s^d$ 称为 $(1 + \gamma)$ -**畸变嵌入**, 若对任意 $p, q \in l_r^t$:

$$\frac{1}{1 + \gamma} \|p - q\|_r \leq \|\phi(p) - \phi(q)\|_s \leq \|p - q\|_r.$$

定理 6 (Figiel–Lindenstrauss–Milman [10]; 论文 Theorem 5) 对任意 $\gamma > 0$, 存在 $(1 + \gamma)$ -畸变嵌入 $\phi: l_2^t \rightarrow l_1^d$, 其中 $d = O(t \log(1/\gamma)/\gamma^2)$ 。Indyk [11] 基于 p -稳定分布给出了此类嵌入的显式随机化构造。

注 5 (为什么约化需要它) $\Pi_{l_2}(t)$ 的间隙存在于 l_2 距离中, 而 F_0 是汉明重量 (本质是 l_1 /计数量)。从 l_2 到比特串没有保距的直接通道, 但 l_1 有: 把坐标放大为整数后做一元编码, l_1 距离恰好变成汉明距离 (见第 5.5 节)。嵌入 ϕ 就是中间的桥。由于 ϕ 是确定性的且 Alice 与 Bob 都知道, 双方可以各自在本地计算 $\phi(x)$ 、 $\phi(y)$, 不消耗任何通信。畸变参数 γ 最终取 $\Theta(\varepsilon)$: 要足够小以使 $(1+\gamma)$ 的伸缩不淹没 $1/\sqrt{t} = \varepsilon$ 的间隙, 但 γ 越小目标维度 d 越大, 直接决定最终全集大小 m ——这就是参数范围 $m^{-1/9}$ 的来源 (第 5.6 节)。

设 $\gamma = \gamma(t)$ 待定。取定理中的嵌入 $\phi: l_2^t \rightarrow l_1^d$ 。对 $(x, y) \in \Pi_{l_2}(t)$, Alice 计算 $\phi(x)$ 、Bob 计算 $\phi(y)$ 。由畸变性质 (取 $q = 0$ 得范数关系, 取一般 p, q 得距离关系):

$$\frac{1}{1+\gamma} \leq |\phi(x)|, |\phi(y)| \leq 1, \quad (1)$$

$$\frac{\|y - x\|}{1+\gamma} \leq |\phi(y) - \phi(x)| \leq \|y - x\|. \quad (2)$$

5.5 从 $\Pi_{l_2}(t)$ 到 F_0 的约化

约化分三步: 有理近似 $\rightarrow$ 通分放大为整数 $\rightarrow$ 一元编码为比特串, 最后把比特串当作流的特征向量。

第一步: 有理近似。 取待定参数 $z = z(t) \in \mathbb{N}$ 。对实数 r , 记 $\{r\}$ 为其小数部分; 存在唯一整数 $s \in [0, z]$ 使 $0 \leq \{r\} - s/z \leq 1/z$, 定义 $\psi(r) = (r - \{r\}) + s/z$ 。对向量逐坐标作用 ψ 。每个坐标改动至多 $1/z$, d 个坐标的 l_1 范数总误差至多 d/z :

$$|\phi(x)| - \frac{d}{z} \leq |\psi(\phi(x))| \leq |\phi(x)| + \frac{d}{z}, \quad (3)$$

$$|\phi(y)| - \frac{d}{z} \leq |\psi(\phi(y))| \leq |\phi(y)| + \frac{d}{z}, \quad (4)$$

$$|\phi(y) - \phi(x)| - \frac{d}{z} \leq |\psi(\phi(y)) - \psi(\phi(x))| \leq |\phi(y) - \phi(x)| + \frac{d}{z}. \quad (5,6)$$

第二步: 通分放大为整数。 将每个坐标乘以公分母 z : 记 $s(v) = (zv_1, \dots, zv_d)$, 则 $s(\psi(\phi(x)))$ 、 $s(\psi(\phi(y)))$ 的所有坐标都是整数, 范数同步放大 z 倍。由 (1)、(3) 知 $|\psi(\phi(x))| \leq 1 + d/z \leq 2$ (将保证 $d = o(z)$), 故每个整数坐标的绝对值 $\leq 2z$ 。

第三步: 一元编码为比特串。 对整数 $i \in [-2z, 2z]$, 定义其一元编码为长 $4z$ 的比特串 $u(i) = 1^{i+2z} 0^{2z-i}$ (前 $2z+i$ 位为 1)。对向量逐坐标编码并拼接: $x' = u(s(\psi(\phi(x))))$, $y' = u(s(\psi(\phi(y))))$, 长度均为 $\Theta(zd)$ (论文记为 $(4z+1)d$)。一元编码的关键性质:

$$|v_1 - v_2| = \Delta(u(v_1), u(v_2)), \quad \text{且} \quad \text{wt}(x') = |s(\psi(\phi(x)))|,$$

即 l_1 距离与汉明距离严格相等, l_1 范数与汉明重量严格相等——放大的 z 倍同时出现在两边。由 (1)(3)(4) 得重量界:

$$z\left(\frac{1}{1+\gamma} - \frac{d}{z}\right) \leq \text{wt}(x'), \text{wt}(y') \leq z\left(1 + \frac{d}{z}\right);$$

由 (2)(5)(6) 得距离界:

$$\frac{z\|y - x\|}{1+\gamma} - d \leq \Delta(x', y') \leq z\|y - x\| + d. \quad (7)$$

第四步：把比特串变成流。 把 x' 、 y' 看作全集 $[m]$ ($m = \Theta(zd)$) 上两条流 $a_{x'}$ 、 $a_{y'}$ 的特征向量，则拼接流 $a_{x'} \circ a_{y'}$ 的特征向量是按位或 $x' \vee y'$ ，故 $F_0(a_{x'} \circ a_{y'}) = \text{wt}(x' \vee y')$ 。

引理 2 (论文 Claim 8) 设 $\beta_1(z) \leq \text{wt}(x'), \text{wt}(y') \leq \beta_2(z)$ ，则

$$\beta_1(z) + \frac{\Delta(x', y')}{2} \leq F_0(a_{x'} \circ a_{y'}) \leq \beta_2(z) + \frac{\Delta(x', y')}{2}.$$

证明. 设 c 为“ y' 为 1 而 x' 为 0”的坐标数。逐位计数得 $\Delta(x', y') = \text{wt}(x') - \text{wt}(y') + 2c$ ，即 $c = \frac{1}{2}(\Delta(x', y') + \text{wt}(y') - \text{wt}(x'))$ 。于是

$$\text{wt}(x' \vee y') = \text{wt}(x') + c = \frac{1}{2}(\Delta(x', y') + \text{wt}(x') + \text{wt}(y')),$$

代入 wt 的上下界即得。 $\square$

两种承诺情形的 F_0 间隙。 **情形 $f(x, y) = 0$ ：**此时 $\|x - y\| = \sqrt{2}$ 。由 (7) 的下端与引理（取 $\beta_1 = z(\frac{1}{1+\gamma} - \frac{d}{z})$ ）：

$$F_0 \geq -\frac{3d}{2} + \frac{z}{1+\gamma} + \frac{z\sqrt{2}}{2+2\gamma} = -\frac{3d}{2} + \frac{z(1 + \frac{1}{\sqrt{2}})}{1+\gamma}.$$

情形 $f(x, y) = 1$ ：此时 $\|x - y\| < \sqrt{2}(1 - \frac{1}{\sqrt{t}})$ 。由 (7) 的上端与引理（取 $\beta_2 = z(1 + \frac{d}{z})$ ）：

$$F_0 \leq \frac{3d}{2} + z\left(1 + \frac{1}{\sqrt{2}}\right) - \frac{z}{\sqrt{2t}}.$$

两情形的主项同为 $z(1 + 1/\sqrt{2})$ ，而间隙为 $\frac{z}{\sqrt{2t}} = \frac{\varepsilon z}{\sqrt{2}}$ （量级 εz ），恰为主项的 $\Theta(\varepsilon)$ 相对间隙；扰动项是 $\pm 3d/2$ 与 $(1 + \gamma)$ 因子。取 $\varepsilon' = c\varepsilon$ ($c = \frac{1}{3(\sqrt{2}+1)}$ 为小常数)，一个 (ε', δ) -近似 F_0 的算法能区分两情形，当且仅当

$$(1 + \varepsilon')\left(\frac{3d}{2} + z\left(1 + \frac{1}{\sqrt{2}}\right) - \frac{\varepsilon z}{\sqrt{2}}\right) < (1 - \varepsilon')\left(-\frac{3d}{2} + \frac{z(1 + \frac{1}{\sqrt{2}})}{1+\gamma}\right). \quad (8)$$

参数求解。 若 $d = o(z\varepsilon)$ ，含 d 的项被吸收，(8) 在 ε 充分小（常数）时等价于

$$(1 + \varepsilon')\left(z\left(1 + \frac{1}{\sqrt{2}}\right) - \frac{\varepsilon z}{\sqrt{2}}\right) < \frac{(1 - \varepsilon')z(1 + \frac{1}{\sqrt{2}})}{1+\gamma}.$$

取 $c = \frac{1}{3(\sqrt{2}+1)}$ ，经代数整理可知 $\gamma = \Theta(\varepsilon)$ 即可使不等式成立。回代各参数：

$$\gamma = \Theta(\varepsilon) \Rightarrow d = O\left(\frac{t \log(1/\gamma)}{\gamma^2}\right) = O\left(\frac{1}{\varepsilon^4} \log \frac{1}{\varepsilon}\right) \Rightarrow z = \omega\left(\frac{1}{\varepsilon^5} \log \frac{1}{\varepsilon}\right) \Rightarrow m = \Theta(zd) = \omega\left(\frac{1}{\varepsilon^9} \log \frac{1}{\varepsilon}\right).$$

于是在全集大小 $m = \Theta(\varepsilon^{-9} \log(1/\varepsilon))$ 上， $(\Theta(\varepsilon), \delta)$ 近似 F_0 的算法可以 δ 误差判定 $\Pi_{t_2}(t)$ ，由约化其空间必为 $\Omega(t) = \Omega(1/\varepsilon^2)$ 。

注 6 (约化的正确性要点) 整条链上信息只经历三次“损耗”：嵌入畸变 $(1+\gamma)$ 、有理近似误差 d/z 、 F_0 估计误差 ε' 。三者都被控制在间隙 εz 之下（分别为 $\gamma = \Theta(\varepsilon)$ 、 $d = o(z\varepsilon)$ 、 $\varepsilon' = \varepsilon/3(\sqrt{2}+1)$ ），因此两种承诺情形在估计值上仍然可分。Alice 发送的是 F_0 算法处理 $a_{x'}$ 后的内部状态，Bob 续跑 $a_{y'}$ 后读出答案——通信量恰为算法空间，故空间 $\geq R^\delta(f) = \Omega(t)$ 。

5.6 主定理的整合与参数范围

定理 7 (主定理 (论文摘要与第 4 节)) 设 $\delta < 1/4$ 为常数, $k > 0$ 为任意常数。任何在大小为 m 的全集上单趟 (ε, δ) -近似 F_0 的数据流算法, 当

$$\varepsilon = \Omega(m^{-1/(9+k)})$$

时必须使用 $\Omega(1/\varepsilon^2)$ 位空间; 对所有更小的 ε , 空间下界为 $\Omega(m^{2/9})$ 量级。

证明链汇总. (1) 固定 ε , 设 $t = \Theta(1/\varepsilon^2)$ 。由论文 Corollary 7, $\Pi_{l_2}(t)$ 的判定需要 $R^\delta(f) = \Omega(t)$ 的单向通信。(2) 由第 5.5 节的约化, 一个空间为 S 的单趟 $(\Theta(\varepsilon), \delta)$ -近似 F_0 算法给出 $\Pi_{l_2}(t)$ 的 S 位单向协议: Alice 将 x 经“嵌入 $\rightarrow$ 有理近似 $\rightarrow$ 放大 $\rightarrow$ 一元编码”变为流 a_x , 运行 F_0 算法并发送其状态; Bob 对 y 做同样变换得到 a_y , 续跑算法并以输出是否超过阈值 $\approx z(1+1/\sqrt{2}) - \frac{1}{2} \cdot \frac{\varepsilon z}{\sqrt{2}}$ 判定 $f(x, y)$ 。两种情形的 F_0 间隙为主项的 $\Theta(\varepsilon)$, 而估计误差为 $\Theta(\varepsilon) < \varepsilon/\sqrt{2}$ (相对主项), 故判定误差 $\leq \delta$ 。(3) 因此 $S = \Omega(t) = \Omega(1/\varepsilon^2)$ 。约化产生的全集大小为 $m = \Theta(\varepsilon^{-9} \log(1/\varepsilon))$, 反解得 $\varepsilon = \Theta((\log m/m)^{1/9})$, 即对任意 $k > 0$, 当 $\varepsilon = \Omega(m^{-1/(9+k)})$ 时下界成立。(4) 对更小的 ε , 取 $\varepsilon_0 = \Theta(m^{-1/9})$ 应用上述构造 (此时约化在同样大小的全集上给出 $\Omega(1/\varepsilon_0^2) = \Omega(m^{2/9})$ 的下界; 对 $\varepsilon < \varepsilon_0$ 的 (ε, δ) -近似同样是 (ε_0, δ) -近似), 即得对所有更小 ε 的 $\Omega(m^{2/9})$ 空间下界。□

注 7 (参数范围与 tightness) 范围限制 $\varepsilon = \Omega(m^{-1/(9+k)})$ 完全来自嵌入的维度膨胀: 确定性嵌入 $d = O(t \log(1/\gamma)/\gamma^2)$ 带来 ε^{-4} , 有理近似的精度要求 $d = o(z\varepsilon)$ 再贡献 ε^{-5} , 合计 $m \approx \varepsilon^{-9}$ 。论文在第 4 节指出两条松动途径: 改用随机化嵌入可将 d 降至 $O(\log t/\gamma^2)$; 而 Woodruff [13] 随后直接在 Hamming 空间构造向量集, 把 $1/\varepsilon$ 的上界推进到最优的 $m^{1/2}$ 。就 tightness 而言: 本文下界 $\Omega(1/\varepsilon^2)$ 与当时最优上界 $O((1/\varepsilon^2 \log \log m + \log m \log(1/\varepsilon)) \log(1/\delta))$ [4] 相比, 小 ε 时相差 $\log \log m$ 、大 ε 时相差 $\log(1/\varepsilon)$ ——关于 ε 的依赖已被完全钉死, 剩余的只是 m 与 δ 方向上的低阶因子 (分别由 [20] 与 [21, 22] 在后续工作中消除)。

6 正确性与优越性分析

6.1 证明正确性的检验

本文证明的核心在于构建了一条严密的约化链: 从欧氏空间中布尔函数判定的单向通信复杂度出发, 最终约化为数据流中不同元素个数 F_0 的近似问题。我们对证明中的关键环节进行正确性检验:

- **嵌入与距离放缩的正确性:** 从 l_2 到 l_1 的低畸变嵌入是约化的桥梁。为了使得承诺问题 $\Pi_{l_2}(t)$ 的两种情形 (内积为 0 或 $2/\sqrt{t}$) 在嵌入后仍能保持可区分的间隙, 作者精心选取了畸变参数 $\gamma = \Theta(\varepsilon)$ 。这一取值既保证了间隙不被放缩畸变淹没, 又为后续的维度推导提供了依据。
- **有理近似的误差控制:** 在将实数坐标转化为整数时, 有理近似引入了至多 d/z 的累积误差 [1]。通过设定公分母 $z = \omega(\frac{1}{\varepsilon^5} \log \frac{1}{\varepsilon})$, 作者严格证明了该误差项 $o(z\varepsilon)$ 完全被主间隙 $\Theta(\varepsilon z)$ 所主导。这严格保证了由汉明重量映射到 F_0 时的可分性, 从而使算法能够以 δ 误差区分两种情形。

- **信息论下界的严密性：**证明利用了 shatter coefficient（打散系数）来界定 VC 维，进而通过 Kremer–Nisan–Ron 定理 [8] 的推广形式得到 $\Omega(t)$ 的通信下界。所构造的大小为 $\Theta(t)$ 的指示向量集，其打散系数严格满足指数级增长的理论下界。这一步的信息论推导无懈可击。

6.2 紧性分析：下界与上界的匹配程度

本文的主要优越性体现在其空间复杂度下界结果的 tightness 上。

- **填补二次方鸿沟：**在本文发表前，最优的 F_0 估计算法空间复杂度为主导项 $O(1/\varepsilon^2)$ ，而最好的空间下界仅为 $\Omega(1/\varepsilon)$ 。本文成功证明了 $\Omega(1/\varepsilon^2)$ 的空间下界，一举跨越了长期悬而未决的二次方鸿沟。
- **渐近最优的匹配：**该下界与当时 Bar-Yossef 等人（2002 [4]）提出的最优上界在核心参数 $1/\varepsilon^2$ 上完全匹配。对于极小的 ε ，上下界仅相差 $\log \log m$ 因子；对于较大的 ε ，上下界仅相差 $\log(1/\varepsilon)$ 因子。
- **理论意义：**这一紧致的下界结论彻底终结了学术界关于“能否将 F_0 近似算法的空间复杂度降低至 $o(1/\varepsilon^2)$ ”的探讨。它确立了对近似误差 ε 的二次方依赖是该问题固有的数学属性，无法被任何算法规避。

6.3 遗留问题及其后续解决

尽管本文在确立主导项复杂度上取得了突破性进展，但受限于约化的技术路线，仍遗留了一些局限，这些局限随后成为了推动该领域研究的重要催化剂：

- **参数 ε 适用范围的局限（ m 依赖性）。遗留问题：**由于证明中采用了从 l_2 映射到 l_1 再到 Hamming 空间的间接约化路线，导致目标维度发生了多项式级的膨胀。因此，本文的 $\Omega(1/\varepsilon^2)$ 下界仅在 $\varepsilon = \Omega(m^{-1/(9+k)})$ 时成立。**后续解决：**正如论文作者在结论中所展望的，可以通过改进或替换嵌入技术来放宽限制。Woodruff（2004 [13]）在后续工作中放弃了间接嵌入路线，直接在 Hamming 空间通过复杂的概率论证构造向量集。该工作将 $1/\varepsilon$ 的上界限放宽至最优的 $m^{1/2}$ ，从而使空间下界适用于更广的参数范围。
- **算法空间复杂度的终极闭合。遗留问题：**本文虽然证明了下界为 $\Omega(1/\varepsilon^2)$ ，但与当时的算法上界之间仍残留着低阶多项式及对数因子的差距。**后续解决：**Kane、Nelson 和 Woodruff（2010 [20]）最终设计出了空间为 $O(1/\varepsilon^2 + \log m)$ 的最优算法。该算法在所有关键参数（不含 δ ）上与本论文下界彻底闭合并消除了残余因子。随后 Blasiok（2018 [22]）进一步完成了包含误差概率 δ 在内的三参数全优刻画。
- **Gap-Hamming-Distance（GHD）问题的启发。**本文的约化技术和内积间隙思想催生了著名的 GHD 通信复杂性问题。作者仅隐含探讨了其单向通信复杂性，而 Chakrabarti 和 Regev（2011 [19]）最终证明了即使在不受限的多轮协议下，GHD 仍然具有最优的 $\Omega(n)$ 通信下界。这使得由本文开创的“通信下界驱动”范式得以在整个数据流理论领域被广泛应用。

7 评价与讨论

本节给出本组对论文的独立评价：第 7.1 节讨论其非凡之处，第 7.2 节提出局限与批评，第 7.3 节分析其对后续研究的影响。

7.1 论文的非凡之处

1. 问对了问题，并且答得干净利落。 2002 年前后， F_0 估计的上界停滞在 $\tilde{O}(1/\varepsilon^2)$ ，下界停滞在 $\Omega(1/\varepsilon)$ ，“二次方鸿沟”是整个数据流社区公开的尴尬。本文没有在上界侧继续堆砌技巧，而是直接回答“ $1/\varepsilon^2$ 是不是问题固有的”这一根本问题，并给出肯定答案。事后看，这个答案一次性地终结了算法设计上“继续优化 $1/\varepsilon$ 依赖”的所有幻想——好的下界和好的算法一样能推动领域前进，本文是这一点的教科书式例证。

2. 方法论上的真正创新：给数据流下界装上了“信息论 + 几何”的引擎。 此前流式下界的约化源都是组合式通信问题（EQ、set disjointness），它们的通信复杂度自带容易达到的协议上界，天花板分别是 $\log m$ 和 $1/\varepsilon$ 。本文的关键洞察是：要突破天花板，必须换一个“只有 F_0 算法的全部能力才能解”的 *promise* 问题。欧氏空间中的内积判定 $\Pi_{l_2}(t)$ 恰好满足这一点——它的函数族包含全部重量 $-t/4$ 的指示函数，丰富到任何协议（包括采样协议）都必须传 $\Omega(t)$ 位。为把这种几何问题的复杂度“搬运”到汉明空间，论文串联起 VC 维/shatter coefficient 的信息论工具与 $l_2 \rightarrow l_1$ 低畸变嵌入这两套此前很少在流式下界中同框出现的 machinery，开创了“几何 promise 问题 $\rightarrow$ 嵌入 $\rightarrow$ 汉明空间 $\rightarrow$ 流”的证明范式。这条流水线此后被反复复用，成为数据流下界证明的标准工艺之一。

3. 一个副产品比主定理还要长寿：Gap-Hamming 问题。 本文正式提出的 Gap-Hamming-Distance 问题（判定两比特串汉明距离 $\geq n/2 + \sqrt{n}$ 还是 $\leq n/2 - \sqrt{n}$ ）在随后十年成为理论计算机科学中最高产的通信问题之一：它的多轮下界 [18]、最优下界 [19] 牵动了 round elimination、高斯空间相关性、信息复杂度等多个方向的工具发展，其影响早已溢出 F_0 本身，渗透到频率矩、熵估计、图流等一大批问题的下界证明中。一篇 6 页的会议论文同时贡献了一个紧下界和一个“下界制造机”，这在文献中并不多见。

4. 工具皆为成熟成品，组合方式却出人意料。 Yao 原则（1977）、VC 维（1971）、KNR 定理（1999）、FLM 嵌入（1977）、一元编码——链条上没有任何一个零件是新的，但整台机器是新的。这体现了作者对两个领域（通信复杂性与度量嵌入）工具箱的同时精通，也使得证明在技术上异常扎实：每一步都可以引用现成的强定理，审稿时没有薄弱环节。对我们学习者而言，这是“创新可以来自跨界组合而非单点突破”的极佳示范。

7.2 局限与批评

1. 参数范围不够紧致，留下了 $m^{-1/9}$ 与 $m^{-1/2}$ 之间的 gap。 本文下界仅在 $\varepsilon = \Omega(m^{-1/(9+k)})$ 时给出 $\Omega(1/\varepsilon^2)$ ；对更小（更高精度要求）的 ε ，只剩 $\Omega(m^{2/9})$ 的平庸下界，与上界 $\tilde{O}(1/\varepsilon^2)$ 相去甚远。根源是技术性的：确定性嵌入带来 $d = O(\varepsilon^{-4} \log(1/\varepsilon))$ 的维度膨胀，有理近似的精度要求再放大出 ε^{-5} 。作者自己在结论中也承认可用随机化嵌入松动该界，而最终由 Woodruff [13]

直接构造解决——这说明本文的 $1/9$ 指数并非问题的本质，而是约化路线的“过路费”。换言之，主定理的结论是紧的，但其证明并非最经济的。

2. 模型覆盖面容。 下界只针对单趟、纯插入 (insertion-only) 流：不覆盖多趟扫描（尽管后来的 GHD 最优下界 [19] 顺带解决了这一点）、不允许元素删除 (turnstile 模型)、不涉及滑动窗口；同时只约束空间，对更新时间、哈希函数的随机性代价（实际实现中“真随机哈希”并不存在）均不置一词。此外 δ 被固定为常数，亚常数误差概率下 $\log(1/\delta)$ 因子是否必要，留给了 Jayram–Woodruff [21]。这些留白今天看都已被后续工作填补，但读者需意识到本文结论的适用边界。

3. 行文密度过高，存在若干伤读者的小瑕疵。 全文仅 6 页，大量代数推导被压缩为“after some algebra”；常数 c 、 ε_0 、 z 的选取只给结论不给动机。更令人困扰的是几处不一致：引言中 $\Pi_{l_2}(t)$ 的内积间隙写作 $1/\sqrt{t}$ ，正文定义与推导却用 $2/\sqrt{t}$ ；一元编码长度按定义为 $4z$ ，文中却记比特串长为 $(4z+1)d$ 。这些不影响结论的正确性，但显著增加了独立复现的时间成本——本组在第 5 节的整理中不得不逐一核对原文两处的版本。

4. 结构性直觉着墨不足。 为什么“内积判定”天然具有 $\Omega(1/\varepsilon^2)$ 的复杂度？为什么嵌入必须绕道 l_1 ？论文把这些问题留给读者自行体会，证明读起来像一连串精巧但偶然的代数巧合。直到后来 Gap-Hamming 视角成熟后，“ $1/\varepsilon^2$ 来自中心极限定理尺度的涨落（ $\sqrt{n}$ 级别的汉明距离间隙）”这一清晰图景才被社区普遍接受。如果论文能给出这一高层叙事，其可读性和影响力还会更进一步。

7.3 对后续研究的影响

下界侧：Gap-Hamming 谱系与“全参数最优”的收尾。 本文遗留的两个 gap—— ε 适用范围与证明的经济性——很快被填平：Woodruff [13] 直接在 Hamming 空间构造，把 $\Omega(1/\varepsilon^2)$ 推进到最优范围 $1/\varepsilon \leq m^{1/2}$ ；Jayram et al. [17]、Brody–Chakrabarti [18]、Chakrabarti–Regev [19] 沿本文提出的 Gap-Hamming 问题逐级推进，最终以任意轮数的 $\Omega(n)$ 最优通信下界收尾，使 F_0 的 $\Omega(1/\varepsilon^2)$ 下界对全参数范围乃至多趟扫描都成立。Jayram–Woodruff [21] 进一步把 $\Omega(\varepsilon^{-2} \log(1/\delta))$ 纳入下界，封闭了 δ 维度。可以说，本文之后 F_0 下界研究的每一步都是在“修缮”而非“推翻”本文的结论。

上界侧：刺激最优算法的诞生。 下界钉死了 $1/\varepsilon^2$ 之后，算法设计的目标变得明确：消去 $\log \log m$ 与 $\log(1/\varepsilon)$ 的残余因子。Kane–Nelson–Woodruff [20] 的 $O(1/\varepsilon^2 + \log m)$ 与 Błasiok [22] 的 $O(\varepsilon^{-2} \log(1/\delta) + \log m)$ 先后达标，且两文的作者都明确以本文下界为对标。上下界在 2018 年于全部参数维度闭合， F_0 估计成为数据流模型中第一个复杂度被完全刻画的基本问题——这个“完结篇”的第一章是本文写的。

范式侧：通信复杂性驱动的流程式下界方法论。 本文巩固并升级了 AMS 开创的“流算法空间 $\geq$ 单向通信复杂度”范式：此后证明流式下界的标准动作变成“设计/借用合适的 promise 通信问题 $\rightarrow$ 信息论工具下界 $\rightarrow$ 嵌入或编码约化到目标问题”。这套方法论外溢到分布式函数监控、

消息传递模型（如 Woodruff–Zhang 关于分布式 F_0 的最优下界）、图流、乃至近年对抗鲁棒流（adversarially robust streaming）的分离结果中，本文的约化技巧始终是这些工作的技术底色。

实践侧：为工程界的对数级空间正名。 HyperLogLog [16] 等工业标准算法用 $\log \log m$ 级寄存器换取常数相对误差；本文及其后续工作从反面证明了：要把相对误差压到 ε ， $\Theta(1/\varepsilon^2)$ 的空间代价一分都不能少。理论下界与工程上界的合流，让“基数估计该花多少内存”第一次有了精确的答案，也为后续 Pettie–Wang 等人关于基数估计信息论极限（Fisher 信息视角）的更精细研究提供了基准。

7.4 本组的理解过程与心得（可选）

8 总结

本文作为数据流算法理论领域的奠基性文献之一，彻底解决了困扰学术界多年的核心开放问题：数据流中不同元素数量（ F_0 ）估计算法的空间复杂度下界究竟是多少。通过巧妙的数学构造与严密的理论推导，作者成功确立了 $\Omega(1/\varepsilon^2)$ 的空间下界，从而填补了此前 $O(1/\varepsilon^2)$ 上界与 $\Omega(1/\varepsilon)$ 下界之间巨大的二次方鸿沟，证明了对近似误差 ε 的二次方依赖是 F_0 估计问题在本质上无法规避的数学属性。

在方法论层面上，作者展现了极高的原创性与技巧性。作者并未局限于传统的组合数学或纯代数方法，而是开创性地构建了一条从“单向通信复杂性”到“数据流算法空间复杂度”的深层约化桥梁。证明过程从欧氏空间的布尔函数判定出发，途经低畸变度量空间嵌入（从 l_2 到 l_1 再到 Hamming 空间），并通过有理近似等精细的误差控制手段，最终精准映射至数据流的 F_0 近似估计问题。这一套基于通信复杂性和距离空间嵌入的跨领域约化范式，不仅完美支撑了本文的证明，更成为了此后推导各类数据流算法（如频率矩估算等）空间下界的通用分析框架与标准工具。

此外，这篇论文的理论遗产远超出了 F_0 估计问题本身。证明过程中对“内积间隙”的探讨以及在 Hamming 空间中的构造思路，直接孕育了著名的 Gap-Hamming-Distance (GHD) 核心难题。GHD 问题在随后的岁月中引发了理论计算机科学界极为丰硕的研究，吸引了众多顶尖学者的跟进与攻坚（并最终于 2011 年由 Chakrabarti 与 Regev [19] 彻底解决），极大地推动了多轮通信复杂性理论的发展。

综上所述，论文以其突破性的核心结论、优雅且深邃的证明技巧，以及对后续研究无可估量的启发价值，在理论计算机科学发展史上留下了浓墨重彩的一笔。它不仅是对 F_0 估计这一特定算法极限的精准标定，更是对“计算资源与近似精度之间内在权衡”这一深刻理论问题的完美数学诠释。

参考文献

- [1] P. Indyk and D. P. Woodruff. Tight lower bounds for the distinct elements problem. In *Proc. 44th IEEE Symposium on Foundations of Computer Science (FOCS)*, pages 283–288, 2003.
- [2] P. Flajolet and G. N. Martin. Probabilistic counting algorithms for data base applications. *Journal of Computer and System Sciences*, 31(2):182–209, 1985.

- [3] N. Alon, Y. Matias, and M. Szegedy. The space complexity of approximating the frequency moments. In *Proc. 28th ACM STOC*, pages 20–29, 1996; journal version: *Journal of Computer and System Sciences*, 58(1):137–147, 1999.
- [4] Z. Bar-Yossef, T. S. Jayram, R. Kumar, D. Sivakumar, and L. Trevisan. Counting distinct elements in a data stream. In *Proc. 6th International Workshop on Randomization and Approximation Techniques (RANDOM)*, LNCS 2483, pages 1–10, 2002.
- [5] Z. Bar-Yossef. *The Complexity of Massive Data Set Computations*. Ph.D. thesis, University of California, Berkeley, 2002.
- [6] A. C.-C. Yao. Probabilistic computations: Toward a unified measure of complexity. In *Proc. 18th IEEE FOCS*, pages 222–227, 1977.
- [7] V. N. Vapnik and A. Y. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and its Applications*, 16(2):264–280, 1971.
- [8] I. Kremer, N. Nisan, and D. Ron. On randomized one-round communication complexity. *Computational Complexity*, 8(1):21–49, 1999.
- [9] Z. Bar-Yossef, T. S. Jayram, R. Kumar, and D. Sivakumar. An information statistics approach to data stream and communication complexity. In *Proc. 17th IEEE Conference on Computational Complexity (CCC)*, pages 93–102, 2002.
- [10] T. Figiel, J. Lindenstrauss, and V. D. Milman. The dimension of almost spherical sections of convex bodies. *Acta Mathematica*, 139:53–94, 1977.
- [11] P. Indyk. Stable distributions, pseudorandom generators, embeddings and data stream computation. In *Proc. 41st IEEE FOCS*, pages 189–197, 2000; journal version: *Journal of the ACM*, 53(3):307–323, 2006.
- [12] P. Indyk. Algorithmic applications of low-distortion geometric embeddings. In *Proc. 42nd IEEE FOCS* (invited talk), pages 10–33, 2001.
- [13] D. P. Woodruff. Optimal space lower bounds for all frequency moments. In *Proc. 15th ACM-SIAM SODA*, pages 167–175, 2004.
- [14] P. B. Gibbons and S. Tirthapura. Estimating simple functions on the union of data streams. In *Proc. 13th ACM SPAA*, pages 281–291, 2001.
- [15] M. Durand and P. Flajolet. Loglog counting of large cardinalities. In *Proc. 11th European Symposium on Algorithms (ESA)*, LNCS 2832, pages 605–617, 2003.

- [16] P. Flajolet, É. Fusy, O. Gandouet, and F. Meunier. HyperLogLog: The analysis of a near-optimal cardinality estimation algorithm. In *Proc. 18th International Meeting on Probabilistic, Combinatorial and Asymptotic Methods for the Analysis of Algorithms (AofA)*, DMTCS Proceedings, pages 127–146, 2007.
- [17] T. S. Jayram, R. Kumar, and D. Sivakumar. The one-way communication complexity of Hamming distance. *Theory of Computing*, 4(1):129–135, 2008.
- [18] J. Brody and A. Chakrabarti. A multi-round communication lower bound for Gap Hamming and some consequences. In *Proc. 24th IEEE Conference on Computational Complexity (CCC)*, pages 358–368, 2009.
- [19] A. Chakrabarti and O. Regev. An optimal lower bound on the communication complexity of Gap-Hamming-Distance. In *Proc. 43rd ACM STOC*, pages 51–60, 2011; journal version: *SIAM Journal on Computing*, 41(5):1299–1317, 2012.
- [20] D. M. Kane, J. Nelson, and D. P. Woodruff. An optimal algorithm for the distinct elements problem. In *Proc. 29th ACM PODS*, pages 41–52, 2010.
- [21] T. S. Jayram and D. P. Woodruff. Optimal bounds for Johnson–Lindenstrauss transforms and streaming problems with subconstant error. In *Proc. 22nd ACM-SIAM SODA*, pages 1–10, 2011; journal version: *ACM Transactions on Algorithms*, 9(3):26:1–26:17, 2013.
- [22] J. Błasiok. Optimal streaming and tracking distinct elements with high probability. In *Proc. 29th ACM-SIAM SODA*, pages 2432–2448, 2018; journal version: *ACM Transactions on Algorithms*, 16(1):3:1–3:28, 2020.
- [23] D. P. Woodruff. The average-case complexity of counting distinct elements. In *Proc. 12th International Conference on Database Theory (ICDT)*, pages 284–295, 2009.
- [24] S. Chakraborty, N. V. Vinodchandran, and K. S. Meel. Distinct elements in streams: An algorithm for the (text) book. In *Proc. 30th European Symposium on Algorithms (ESA)*, LIPIcs 244, pages 34:1–34:6, 2022.